

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ PHẦN MỀM

BÁO CÁO ĐỒ ÁN / NGHIÊN CỨU KHOA HỌC

**PHÁT HIỆN SAI PHẠM TRONG QUẢNG CÁO THỰC
PHẨM CHỨC NĂNG TRÊN MẠNG XÃ HỘI**

Giảng viên hướng dẫn: Đỗ Trọng Hợp

Sinh viên thực hiện: Hồ Nguyên Vũ

Mã số sinh viên: 23521805

Lớp: SE365

TP. HỒ CHÍ MINH, THÁNG 06 NĂM 2026

Mục lục

1	MỞ ĐẦU	1
1.1	Bối cảnh đề tài	1
1.2	Vấn đề nghiên cứu	1
1.3	Mục tiêu đề tài	2
1.4	Phạm vi nghiên cứu	3
1.4.1	Yêu cầu chức năng hệ thống	4
1.4.2	Yêu cầu chức năng dữ liệu	5
1.5	Đóng góp dự kiến	6
2	CƠ SỞ LÝ THUYẾT VÀ PHÁP LÝ	7
2.1	Tổng quan về quảng cáo thực phẩm chức năng	7
2.2	Cơ sở pháp lý	7
2.3	Các công nghệ sử dụng	7
2.3.1	Google Colab và GPU NVIDIA T4	8
2.3.2	Python	8
2.3.3	Pandas và NumPy	9
2.3.4	PyTorch	9
2.3.5	Hugging Face Transformers	10
2.3.6	PhoBERT-base-v2	10
2.3.7	Hugging Face Datasets	11
2.3.8	Scikit-learn	11

2.3.9	Định dạng CSV và JSON	12
2.3.10	Weighted loss và early stopping	12
2.4	Các nhóm dấu hiệu sai phạm trong văn bản	13
2.5	Bài toán phân loại đa nhãn	13
2.6	Các hướng tiếp cận liên quan	14
3	DỮ LIỆU VÀ QUY TRÌNH GÁN NHÃN	15
3.1	Nguồn dữ liệu	15
3.2	Quy trình thu thập dữ liệu	15
3.3	Định dạng dữ liệu	16
3.4	Bộ nhãn sử dụng	16
3.5	Nguyên tắc gán nhãn	16
3.6	Chia tập dữ liệu	17
4	PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	18
4.1	Kiến trúc hệ thống	18
4.2	Thiết kế UC	20
4.2.1	Đặc tả UC01 – Thu thập dữ liệu	22
5	PHƯƠNG PHÁP ĐỀ XUẤT	25
5.1	Tổng quan kiến trúc hệ thống	25
5.2	Tiền xử lý văn bản	26
5.3	Mô hình phân loại đa nhãn	27
5.3.1	Thử nghiệm và tối ưu mô hình PhoBERT cho phân loại đa nhãn . . .	27
5.4	Điều chỉnh ngưỡng dự đoán	29
5.5	Hậu xử lý và luật hỗ trợ	29
6	THỰC NGHIỆM VÀ ĐÁNH GIÁ	30
6.1	Thiết lập thực nghiệm	30

6.2	Thống kê dữ liệu	30
6.3	Chỉ số đánh giá	31
6.4	Kết quả thực nghiệm	31
6.5	Phân tích lỗi	33
6.6	Thảo luận	33
7	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	35
7.1	Kết luận	35
7.2	Ưu điểm	35
7.3	Hạn chế	35
7.4	Hướng phát triển	35
	TÀI LIỆU THAM KHẢO	37

Danh sách bảng

2.1	Nhóm dấu hiệu sai phạm trong nội dung văn bản	13
3.1	Định dạng dữ liệu đề xuất	16
3.2	Bộ nhãn phân loại dự kiến	16
4.1	Đặc tả use case UC01 – Thu thập dữ liệu	22
5.1	Tóm tắt các cấu hình thử nghiệm với mô hình PhoBERT	28
5.2	Bảng ngưỡng dự đoán cho từng nhãn	29
6.1	Thống kê số lượng mẫu theo tập dữ liệu	30
6.2	Thống kê phân phối nhãn	31
6.3	Threshold cuối cùng dùng để đánh giá validation/test	31
6.4	Kết quả tổng quan trên validation và test	32
6.5	Kết quả đánh giá theo từng nhãn trên tập test	32
6.6	So sánh F1 theo từng nhãn trên validation và test	33

Danh sách hình vẽ

4.1	Kiến trúc tổng thể của hệ thống phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng	20
4.2	Use case UC01 – Thu thập dữ liệu	22
5.1	Pipeline huấn luyện mô hình PhoBERT multi-label để phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng.	26

CHƯƠNG 1:

MỞ ĐẦU

1.1 Bối cảnh đề tài

Sự phát triển mạnh của các nền tảng mạng xã hội như Facebook, TikTok và các kênh nội dung ngắn đã làm thay đổi đáng kể cách sản phẩm thực phẩm chức năng, thực phẩm bảo vệ sức khỏe được quảng bá đến người tiêu dùng. Nội dung quảng cáo không còn chỉ xuất hiện dưới dạng văn bản tĩnh, mà thường được kết hợp giữa bài đăng, video, phụ đề, chữ chèn trong ảnh, lời thoại, hình ảnh chuyên gia, phản hồi người dùng và các hình thức khuyến mãi có tính lan truyền cao. Đặc điểm này giúp quảng cáo tiếp cận người dùng nhanh hơn, nhưng đồng thời cũng khiến việc kiểm tra, giám sát và phát hiện sai phạm bằng phương pháp thủ công trở nên khó khăn.

Trong thực tế, nhiều nội dung quảng cáo thực phẩm chức năng có dấu hiệu thổi phồng công dụng, gây hiểu nhầm về khả năng điều trị bệnh, lợi dụng hình ảnh hoặc uy tín của bác sĩ, bệnh viện, cơ quan nhà nước, báo chí, hoặc khai thác tâm lý lo sợ của người tiêu dùng. Một số quảng cáo còn sử dụng ký tự đặc biệt, teencode, cách viết biến dạng, hình ảnh hoặc video để né tránh các bộ lọc đơn giản. Bối cảnh pháp lý liên quan đến quảng cáo thực phẩm và thực phẩm bảo vệ sức khỏe đặt ra yêu cầu cần có các công cụ hỗ trợ rà soát rủi ro, giúp phát hiện sớm các nội dung có dấu hiệu vi phạm trước khi tiến hành đánh giá chuyên sâu.

1.2 Vấn đề nghiên cứu

Bài toán nghiên cứu của đề tài là xây dựng một pipeline hỗ trợ tự động thu thập, xử lý, gán nhãn, huấn luyện mô hình và đánh giá các nội dung quảng cáo thực phẩm chức năng trên mạng xã hội. Hệ thống không nhằm đưa ra kết luận pháp lý cuối cùng thay cho cơ quan chức năng, mà đóng vai trò như một công cụ hỗ trợ phát hiện và ưu tiên rà soát các mẫu

quảng cáo có rủi ro cao.

Ở giai đoạn hiện tại, đề tài không chỉ dừng ở phân loại văn bản, mà hướng đến một hệ thống phát hiện rủi ro đa phương thức. Văn bản bài đăng, caption, phụ đề, chữ OCR trong ảnh/video, nội dung ASR từ lời nói, tín hiệu hình ảnh và luật phát hiện đều được xem là các nguồn thông tin bắt buộc trong pipeline. Một mẫu quảng cáo có thể đồng thời chứa nhiều dấu hiệu rủi ro, chẳng hạn vừa là nội dung quảng cáo, vừa có tuyên bố công dụng quá mức, tuyên bố chữa bệnh, trích dẫn uy tín y tế, nhân chứng khỏi bệnh, yếu tố hù dọa hoặc khuyến mãi gây áp lực. Do đó, hệ thống cần kết hợp nhiều nguồn tín hiệu để nhận diện được các nhóm dấu hiệu sai phạm khác nhau trong cùng một mẫu dữ liệu.

1.3 Mục tiêu đề tài

Đề tài hướng đến các mục tiêu chính sau:

- Xây dựng quy trình thu thập dữ liệu quảng cáo thực phẩm chức năng, thực phẩm bảo vệ sức khỏe từ các nền tảng mạng xã hội, có lưu trữ nội dung văn bản, nguồn dữ liệu, thời gian đăng tải, định danh mẫu và metadata cần thiết.
- Đề xuất và chuẩn hóa bộ nhãn phục vụ phát hiện các nhóm dấu hiệu rủi ro phổ biến trong quảng cáo, bao gồm tính chất quảng cáo, tuyên bố công dụng, tuyên bố chữa bệnh, lợi dụng uy tín, nhân chứng, yếu tố hù dọa, khuyến mãi và cảnh báo bắt buộc nếu có.
- Xây dựng pipeline xử lý dữ liệu đa nguồn, bao gồm văn bản bài đăng, caption, phụ đề, OCR từ ảnh/video, ASR từ lời nói, frame hình ảnh, metadata và các tín hiệu luật/keyword.
- Xây dựng các mô hình baseline từ luật/keyword và học máy truyền thống, phát triển mô hình phân loại đa nhãn cho văn bản, đồng thời tích hợp các module OCR, ASR và phát hiện tín hiệu hình ảnh rủi ro.
- Đánh giá mô hình bằng các chỉ số phù hợp cho bài toán đa nhãn như micro F1, macro

F1, precision, recall, exact match accuracy và F1 riêng cho từng nhãn; đồng thời thực hiện phân tích lỗi để cải thiện dữ liệu và mô hình.

- Xây dựng cơ chế kết hợp đa phương thức giữa văn bản, OCR, ASR, tín hiệu hình ảnh và luật phát hiện để tạo nhãn dự đoán, xác suất và điểm rủi ro tổng hợp.

1.4 Phạm vi nghiên cứu

Phạm vi nghiên cứu hiện tại bao gồm cả dữ liệu văn bản và dữ liệu đa phương thức trong nội dung quảng cáo trên mạng xã hội. Hệ thống xử lý văn bản từ bài đăng, mô tả, caption và phụ đề; trích xuất chữ trong ảnh hoặc video bằng OCR; chuyển lời nói trong video thành văn bản bằng ASR; phân tích frame hình ảnh để nhận diện các tín hiệu rủi ro như bác sĩ, áo blouse, ống nghe, phòng khám, logo cơ quan/báo chí hoặc hình thức testimonial trực quan; đồng thời kết hợp với luật/keyword để hỗ trợ phát hiện dấu hiệu sai phạm.

Trong đó, mô hình PhoBERT là module phân loại văn bản chính nhưng không phải toàn bộ hệ thống. Các nhánh như PhoBERT, OCR, ASR, visual detection và rule-based detection được thiết kế chạy song song, mỗi nhánh tạo ra điểm dự đoán riêng. Kết quả cuối cùng được tạo từ quá trình hợp nhất nhiều nguồn tín hiệu, bao gồm phobert_score, OCR_score, ASR_score, visual_score và rule_score. Cơ chế kết hợp ban đầu có thể theo hướng late fusion để tạo risk_score, sau đó điều chỉnh theo kết quả thực nghiệm.

Các nhóm nhãn đầu ra dự kiến gồm:

- IS_ADS: nội dung có tính quảng cáo.
- EFFICACY_CLAIM: tuyên bố công dụng hoặc thời phòng hiệu quả.
- CURE_CLAIM: tuyên bố chữa bệnh hoặc điều trị khỏi bệnh.
- AUTHORITY_REFERENCE: lợi dụng uy tín của bác sĩ, bệnh viện, cơ quan nhà nước, báo chí hoặc tổ chức uy tín.
- TESTIMONIAL: nhân chứng, bệnh nhân hoặc câu chuyện khỏi bệnh.
- FEAR_URGENCY: hù dọa, tạo áp lực, FOMO hoặc khan hiếm giả.

- **PRICE_PROMOTION:** ưu đãi, giảm giá, khuyến mãi hoặc cam kết hoàn tiền.

Các nhãn này được sử dụng cho mô hình văn bản và cho tăng hợp nhất đa phương thức. Khi dữ liệu đủ điều kiện, bộ nhãn có thể mở rộng thêm nhóm phát hiện thiếu hoặc che khuất cảnh báo bắt buộc. Đối với ảnh và video, hệ thống không chỉ dựa vào nhãn văn bản, mà còn cần ghi nhận các bằng chứng trực quan hoặc âm thanh tương ứng, chẳng hạn chữ quảng cáo xuất hiện trong frame, lời thoại khẳng định công dụng, hình ảnh bác sĩ/chuyên gia, logo tổ chức uy tín hoặc testimonial trong poster/video.

Đề tài giới hạn ở mức phát hiện dấu hiệu và hỗ trợ rà soát rủi ro. Kết quả của hệ thống là nhãn dự đoán, xác suất, điểm rủi ro và bằng chứng hỗ trợ, không phải kết luận vi phạm pháp luật cuối cùng.

1.4.1 Yêu cầu chức năng hệ thống

Để đáp ứng phạm vi nghiên cứu nêu trên, hệ thống cần được thiết kế theo kiến trúc module, trong đó mỗi module đảm nhiệm một nhóm chức năng riêng nhưng có thể kết nối thành pipeline xử lý thống nhất. Các yêu cầu chức năng chính của hệ thống bao gồm:

- **Data Collection Module:** thu thập bài đăng, hình ảnh hoặc video từ TikTok và Facebook; lưu metadata, đường dẫn file hoặc video, nguồn dữ liệu và văn bản thô đi kèm.
- **Data Processing & Labeling Module:** chuẩn hóa dữ liệu, kiểm tra trùng lặp, quản lý bộ nhãn, chia tập train/validation/test và lưu phiên bản dataset phục vụ tái lập thực nghiệm.
- **Rule-based Detection Module:** đọc file keyword.json, phát hiện các cụm từ rủi ro, trả về nhãn gợi ý và đoạn bằng chứng tương ứng trong văn bản.
- **PhoBERT Classification Module:** huấn luyện và suy luận mô hình PhoBERT cho bài toán phân loại đa nhãn văn bản, trả về xác suất theo từng nhãn.
- **OCR Module:** trích xuất frame từ video và nhận diện chữ được nhúng trong ảnh hoặc video, nhằm bổ sung tín hiệu văn bản ngoài phần caption.

- **ASR Module:** trích xuất audio từ video và chuyển lời nói thành văn bản bằng Whisper hoặc mô hình nhận dạng tiếng nói tương đương.
- **Visual Detection Module:** phát hiện các tín hiệu hình ảnh có rủi ro như áo blouse trắng, ống nghe, bối cảnh phòng khám, logo giả mạo hoặc hình ảnh chuyên gia y tế.
- **Fusion & Risk Scoring Module:** kết hợp điểm từ PhoBERT, OCR, ASR, hình ảnh và luật phát hiện để tạo điểm rủi ro tổng hợp cho từng mẫu dữ liệu.
- **RAG & LLM Reasoning Module:** truy xuất quy định, nguyên tắc gán nhãn và bằng chứng liên quan, sau đó sinh kết luận có giải thích để hỗ trợ người rà soát.
- **Inference API/Demo Module:** cung cấp endpoint /predict nhận văn bản hoặc metadata bài đăng, trả về nhãn, xác suất, bằng chứng và phân giải thích.

1.4.2 Yêu cầu chức năng dữ liệu

Bên cạnh các module xử lý, hệ thống cần có yêu cầu rõ ràng đối với dữ liệu để bảo đảm quá trình huấn luyện, đánh giá và suy luận có thể kiểm soát được. Các yêu cầu chức năng dữ liệu bao gồm:

- **Lưu trữ dữ liệu thô:** lưu nguyên trạng văn bản bài đăng, caption, mô tả video, đường dẫn nguồn, thời gian thu thập, nền tảng, định danh bài đăng và các metadata cần thiết.
- **Quản lý dữ liệu đa phương thức:** liên kết mỗi mẫu với các thành phần tương ứng như ảnh, video, frame trích xuất, audio, kết quả OCR, kết quả ASR và tín hiệu hình ảnh.
- **Chuẩn hóa và làm sạch dữ liệu:** chuẩn hóa Unicode, loại bỏ mẫu rỗng, kiểm tra duplicate, kiểm tra leakage theo bài đăng và chuẩn hóa định dạng nhãn.
- **Quản lý bộ nhãn:** lưu danh sách nhãn, định nghĩa nhãn, nguyên tắc gán nhãn và trạng thái gán nhãn của từng mẫu để hỗ trợ kiểm tra thủ công.
- **Chia tập dữ liệu:** chia dữ liệu thành train, validation và test theo quy tắc nhất quán, hạn chế việc các đoạn thuộc cùng một bài đăng xuất hiện ở nhiều tập khác nhau.

- **Lưu phiên bản dataset:** ghi nhận phiên bản dữ liệu, thời điểm tạo, nguồn dữ liệu, cấu hình tiền xử lý và thống kê phân phối nhãn để có thể tái lập thực nghiệm.
- **Lưu bằng chứng phát hiện:** lưu đoạn văn bản, frame, lời thoại hoặc tín hiệu hình ảnh làm bằng chứng cho từng nhãn gợi ý hoặc nhãn dự đoán.
- **Lưu kết quả mô hình:** lưu xác suất dự đoán, nhãn sau threshold, điểm rủi ro tổng hợp, nhãn sai lệch và ghi chú review để phục vụ phân tích lỗi.
- **Xuất dữ liệu phục vụ đánh giá:** hỗ trợ xuất file CSV hoặc JSON chứa dữ liệu, nhãn, xác suất, bằng chứng và metadata để kiểm tra thủ công hoặc dùng trong các lần huấn luyện tiếp theo.

1.5 Đóng góp dự kiến

Đóng góp dự kiến của đề tài bao gồm:

- Một quy trình dữ liệu có thể tái lập cho bài toán phát hiện sai phạm trong quảng cáo thực phẩm chức năng trên mạng xã hội.
- Một bộ nhãn đa nhãn phản ánh các dạng dấu hiệu rủi ro thường gặp trong nội dung quảng cáo thực phẩm chức năng, thực phẩm bảo vệ sức khỏe.
- Các mô hình baseline gồm rule-based/keyword-based detector và mô hình học máy truyền thống, làm cơ sở so sánh cho các module học sâu và module đa phương thức.
- Mô hình NLP đa nhãn dựa trên transformer tiếng Việt, các module OCR, ASR, phát hiện tín hiệu hình ảnh và cơ chế điều chỉnh threshold theo từng nhãn.
- Quy trình phân tích lỗi và xuất kết quả dự đoán phục vụ review thủ công, cải thiện dataset và huấn luyện lại trong các phiên bản tiếp theo.
- Kiến trúc hợp nhất đa phương thức, kết hợp văn bản, OCR, ASR, tín hiệu hình ảnh và luật phát hiện để xây dựng điểm rủi ro tổng hợp.

CHƯƠNG 2:

CƠ SỞ LÝ THUYẾT VÀ PHÁP LÝ

2.1 Tổng quan về quảng cáo thực phẩm chức năng

Thực phẩm chức năng và thực phẩm bảo vệ sức khỏe là nhóm sản phẩm có liên quan trực tiếp đến nhận thức sức khỏe của người tiêu dùng. Vì vậy, quảng cáo cho nhóm sản phẩm này cần được kiểm soát chặt chẽ, đặc biệt đối với các nội dung gây hiểu nhầm rằng sản phẩm có tác dụng như thuốc chữa bệnh.

2.2 Cơ sở pháp lý

Báo cáo có thể tham chiếu các văn bản pháp lý sau trong quá trình xây dựng tiêu chí phát hiện:

- Luật Quảng cáo 2012 và các văn bản sửa đổi, bổ sung.
- Nghị định 15/2018/NĐ-CP.
- Nghị định 38/2021/NĐ-CP.
- Các văn bản cập nhật liên quan đến xử phạt và quản lý quảng cáo thực phẩm bảo vệ sức khỏe.

2.3 Các công nghệ sử dụng

Trong quá trình xây dựng và thực nghiệm mô hình phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng, đề tài sử dụng một số công nghệ chính phục vụ xử lý dữ liệu, huấn luyện mô hình ngôn ngữ và đánh giá kết quả. Các công nghệ này được lựa chọn dựa trên mức độ phù hợp với bài toán phân loại đa nhãn tiếng Việt, khả năng triển khai trên môi trường Google Colab và khả năng tái lập kết quả thực nghiệm.

2.3.1 Google Colab và GPU NVIDIA T4

Google Colab là nền tảng điện toán đám mây cho phép chạy mã Python trực tiếp trên trình duyệt. Trong thực nghiệm, đề tài sử dụng môi trường Colab với GPU NVIDIA T4 để tăng tốc quá trình fine-tune mô hình PhoBERT.

Ưu điểm. Google Colab dễ sử dụng, không yêu cầu cài đặt môi trường phức tạp trên máy cá nhân và hỗ trợ GPU miễn phí hoặc theo gói trả phí. GPU NVIDIA T4 phù hợp với các mô hình Transformer cỡ vừa như PhoBERT-base-v2, giúp rút ngắn đáng kể thời gian huấn luyện so với CPU.

Nhược điểm. Tài nguyên Colab có giới hạn về thời gian phiên chạy, dung lượng bộ nhớ và mức độ ổn định. GPU được cấp phát có thể thay đổi tùy thời điểm, vì vậy thời gian huấn luyện giữa các lần chạy có thể không hoàn toàn giống nhau.

Lý do chọn. Colab phù hợp với quy mô thực nghiệm của đề tài, đặc biệt khi cần fine-tune mô hình học sâu nhưng không có sẵn máy tính cá nhân cấu hình cao. Việc sử dụng GPU T4 giúp cân bằng giữa hiệu năng, chi phí và khả năng triển khai nhanh.

2.3.2 Python

Python là ngôn ngữ lập trình chính được sử dụng để xây dựng toàn bộ pipeline, bao gồm đọc dữ liệu, kiểm tra chất lượng dữ liệu, tokenization, huấn luyện mô hình, đánh giá và lưu kết quả.

Ưu điểm. Python có hệ sinh thái thư viện mạnh cho học máy và xử lý ngôn ngữ tự nhiên, cú pháp dễ đọc và phù hợp với môi trường notebook như Google Colab.

Nhược điểm. Python có tốc độ thực thi thuần không cao bằng các ngôn ngữ biên dịch. Tuy nhiên, trong bài toán này, các phép tính nặng chủ yếu được thực hiện bởi các thư viện tối ưu hóa như PyTorch và chạy trên GPU.

Lý do chọn. Python là lựa chọn phổ biến trong nghiên cứu học sâu, dễ kết hợp với các thư viện như PyTorch, Transformers, Pandas, NumPy và Scikit-learn. Điều này giúp quá trình thử nghiệm mô hình diễn ra nhanh và thuận tiện.

2.3.3 Pandas và NumPy

Pandas được sử dụng để đọc và xử lý dữ liệu dạng bảng từ file `dataset_real.csv`. NumPy được sử dụng để xử lý mảng số, tính toán thống kê, class weight và threshold cho từng nhãn.

Ưu điểm. Pandas thuận tiện cho thao tác với dữ liệu dạng bảng như lọc mẫu, kiểm tra cột bắt buộc, xử lý giá trị thiếu và chia tập train/validation/test. NumPy hỗ trợ tính toán vector hóa hiệu quả, phù hợp với các thao tác trên ma trận nhãn và xác suất dự đoán.

Nhược điểm. Pandas có thể tiêu tốn nhiều bộ nhớ khi dữ liệu rất lớn. NumPy tuy mạnh về tính toán mảng nhưng không cung cấp trực tiếp các cấu trúc dữ liệu giàu ngữ nghĩa như DataFrame.

Lý do chọn. Dữ liệu của đề tài được tổ chức dưới dạng CSV với nhiều cột nhãn, vì vậy Pandas và NumPy là bộ công cụ phù hợp để kiểm tra, chuẩn hóa và chuẩn bị dữ liệu trước khi đưa vào mô hình.

2.3.4 PyTorch

PyTorch là framework học sâu được sử dụng làm nền tảng tính toán cho mô hình. Trong code thực nghiệm, PyTorch được dùng để kiểm tra GPU, thiết lập seed, tính sigmoid, đưa mô hình lên thiết bị CUDA và cài đặt hàm mất mát BCEWithLogitsLoss.

Ưu điểm. PyTorch linh hoạt, dễ tùy biến và được hỗ trợ tốt bởi các thư viện Transformer hiện đại. Framework này cho phép tận dụng GPU để tăng tốc huấn luyện và suy luận.

Nhược điểm. PyTorch yêu cầu người dùng hiểu rõ tensor, thiết bị tính toán và quá trình huấn luyện mô hình. Nếu quản lý GPU hoặc kiểu dữ liệu không đúng, chương trình có thể gặp lỗi bộ nhớ hoặc lỗi không tương thích thiết bị.

Lý do chọn. PyTorch tương thích trực tiếp với Hugging Face Transformers và phù hợp với việc tùy biến loss cho bài toán phân loại đa nhãn mất cân bằng.

2.3.5 Hugging Face Transformers

Hugging Face Transformers là thư viện được sử dụng để tải tokenizer, mô hình PhoBERT và triển khai quá trình huấn luyện. Trong code, thư viện này cung cấp các thành phần chính như tokenizer tự động, lớp mô hình phân loại chuỗi, cấu hình huấn luyện, Trainer, data collator và callback dừng sớm.

Ưu điểm. Thư viện cung cấp giao diện thống nhất cho nhiều mô hình ngôn ngữ hiện đại, giúp giảm khối lượng code cần tự viết. Lớp Trainer hỗ trợ sẵn các chức năng quan trọng như huấn luyện theo epoch, đánh giá, lưu checkpoint, chọn mô hình tốt nhất và early stopping.

Nhược điểm. Do thư viện đóng gói nhiều chức năng ở mức cao, việc tùy biến sâu đôi khi cần kế thừa lại lớp Trainer hoặc hiểu rõ cơ chế hoạt động bên trong. Ngoài ra, phiên bản thư viện thay đổi có thể làm thay đổi một số tham số cấu hình.

Lý do chọn. Transformers giúp triển khai nhanh mô hình PhoBERT cho bài toán phân loại đa nhãn, đồng thời vẫn cho phép tùy biến hàm loss thông qua lớp Trainer mở rộng.

2.3.6 PhoBERT-base-v2

PhoBERT-base-v2 là mô hình ngôn ngữ tiền huấn luyện cho tiếng Việt, được sử dụng như một encoder văn bản trong kiến trúc nhiều nhánh. Trong thực nghiệm, mô hình được tải bằng lớp phân loại chuỗi của thư viện Transformers, đặt số đầu ra bằng số nhãn cần dự đoán và cấu hình theo hướng phân loại đa nhãn.

Ưu điểm. PhoBERT được huấn luyện trên dữ liệu tiếng Việt nên có khả năng biểu diễn ngữ nghĩa tốt với văn bản tiếng Việt. Phiên bản base có kích thước vừa phải, phù hợp để fine-tune trên GPU T4 trong môi trường Google Colab.

Nhược điểm. Mô hình Transformer cần nhiều tài nguyên tính toán hơn các phương pháp truyền thống như từ khóa hoặc học máy cổ điển. Hiệu quả của mô hình cũng phụ thuộc nhiều vào chất lượng dữ liệu gán nhãn và mức độ cân bằng giữa các nhãn trong tập huấn

luyện.

Lý do chọn. Bài toán của đề tài tập trung vào văn bản quảng cáo tiếng Việt, có nhiều cách diễn đạt linh hoạt và phụ thuộc mạnh vào ngữ cảnh. PhoBERT-base-v2 phù hợp vì có khả năng học đặc trưng ngôn ngữ tiếng Việt và có thể fine-tune cho phân loại đa nhãn.

2.3.7 Hugging Face Datasets

Hugging Face Datasets được sử dụng để chuyển dữ liệu từ Pandas DataFrame sang định dạng Dataset, sau đó ánh xạ hàm tokenization lên các tập train, validation và test.

Ưu điểm. Thư viện này tích hợp tốt với Transformers Trainer, hỗ trợ xử lý dữ liệu theo batch và giúp pipeline huấn luyện gọn hơn.

Nhược điểm. Với các bài toán nhỏ, việc chuyển đổi từ DataFrame sang Dataset có thể làm tăng thêm một bước xử lý. Người dùng cũng cần chú ý loại bỏ các cột không cần thiết trước khi đưa dữ liệu vào Trainer.

Lý do chọn. Datasets giúp chuẩn hóa định dạng đầu vào cho Hugging Face Trainer, từ đó giảm lỗi trong quá trình tokenization, batching và huấn luyện.

2.3.8 Scikit-learn

Scikit-learn được sử dụng để tính các chỉ số đánh giá gồm exact match accuracy, precision, recall, macro F1, micro F1 và classification report.

Ưu điểm. Scikit-learn cung cấp các hàm đánh giá ổn định, dễ sử dụng và phù hợp với bài toán phân loại đa nhãn. Các tham số như `average="macro"`, `average="micro"` và `zero_division=0` giúp kiểm soát cách tính chỉ số trong trường hợp nhãn hiếm.

Nhược điểm. Scikit-learn chủ yếu phục vụ xử lý và đánh giá trên CPU, không phải framework huấn luyện mô hình Transformer. Vì vậy, thư viện này được dùng bổ trợ thay vì thay thế PyTorch hoặc Transformers.

Lý do chọn. Các chỉ số của Scikit-learn phù hợp để đánh giá hiệu quả mô hình ở cả mức tổng quan và từng nhãn, đặc biệt trong bối cảnh dữ liệu mất cân bằng.

2.3.9 Định dạng CSV và JSON

CSV được sử dụng làm định dạng dữ liệu đầu vào và lưu file dự đoán trên tập test. JSON được sử dụng để lưu các thông tin cấu hình như danh sách nhãn, threshold cuối cùng và metadata của quá trình huấn luyện.

Ưu điểm. CSV dễ tạo, dễ đọc bằng Pandas và thuận tiện cho việc kiểm tra thủ công bằng các phần mềm bảng tính. JSON phù hợp để lưu cấu hình có cấu trúc, dễ đọc lại khi triển khai hoặc tái lập thực nghiệm.

Nhược điểm. CSV không lưu được kiểu dữ liệu phức tạp một cách chặt chẽ và dễ phát sinh lỗi nếu dữ liệu chứa dấu phân tách không được xử lý đúng. JSON không tối ưu cho dữ liệu dạng bảng lớn.

Lý do chọn. Hai định dạng này đơn giản, phổ biến và phù hợp với quy mô đề tài. CSV thuận tiện cho dữ liệu gán nhãn, còn JSON phù hợp để lưu thông tin phụ trợ của mô hình.

2.3.10 Weighted loss và early stopping

Do dữ liệu có hiện tượng mất cân bằng giữa các nhãn, đề tài sử dụng BCEWithLogitsLoss kết hợp pos_weight. Trọng số dương được tính từ tỷ lệ mẫu âm/dương, sau đó làm mềm bằng căn bậc hai và chặn trong khoảng hợp lý. Ngoài ra, EarlyStoppingCallback được sử dụng để dừng huấn luyện khi kết quả validation không tiếp tục cải thiện.

Ưu điểm. Weighted loss giúp mô hình chú ý hơn đến các nhãn hiếm, hạn chế tình trạng mô hình chỉ học tốt các nhãn phổ biến. Early stopping giúp giảm nguy cơ overfit và tiết kiệm thời gian huấn luyện.

Nhược điểm. Nếu trọng số dương quá lớn, mô hình có thể dự đoán quá nhiều nhãn dương và làm tăng false positive. Early stopping cũng phụ thuộc vào tập validation, nên nếu validation nhỏ hoặc chưa đại diện tốt thì quyết định dừng có thể chưa tối ưu.

Lý do chọn. Bài toán phân loại sai phạm quảng cáo là bài toán đa nhãn và có một số nhãn hiếm như TESTIMONIAL hoặc FEAR_URGENCY. Vì vậy, weighted loss và early stopping

được sử dụng để cân bằng giữa khả năng học nhãn hiếm, kiểm soát overfit và giữ quá trình huấn luyện ổn định.

2.4 Các nhóm dấu hiệu sai phạm trong văn bản

Bảng 2.1. Nhóm dấu hiệu sai phạm trong nội dung văn bản

Nhóm dấu hiệu	Mô tả ngắn
Thổi phồng công dụng	Cam kết khỏi bệnh, dùng các cụm từ tuyệt đối như “khỏi 100%”, “trị tận gốc”, “chữa dứt điểm”.
Tuyên bố chữa bệnh	Gán cho sản phẩm vai trò như thuốc, phác đồ điều trị hoặc phương pháp chữa bệnh.
Lợi dụng uy tín	Sử dụng tên bác sĩ, bệnh viện, cơ quan y tế, truyền thông hoặc chứng nhận để tạo niềm tin sai lệch.
Nhân chứng/đánh giá	Dùng câu chuyện bệnh nhân, thư cảm ơn, hình ảnh trước-sau hoặc trải nghiệm cá nhân để tạo bằng chứng cảm tính.
Hù dọa/FOMO	Tạo áp lực bằng biến chứng nguy hiểm, khan hiếm giả tạo, ưu đãi giới hạn hoặc lời kêu gọi mua ngay.

2.5 Bài toán phân loại đa nhãn

Trong thực tế, một quảng cáo có thể đồng thời chứa nhiều dấu hiệu sai phạm. Vì vậy, bài toán được mô hình hóa theo hướng phân loại đa nhãn, trong đó mỗi mẫu văn bản có thể được gán nhiều nhãn cùng lúc thay vì chỉ thuộc một lớp duy nhất.

2.6 Các hướng tiếp cận liên quan

Các hướng tiếp cận có thể được trình bày gồm phương pháp dựa trên từ khóa, học máy truyền thống, mô hình ngôn ngữ tiếng Việt và mô hình đa phương thức. Phần này nên so sánh ưu nhược điểm của từng hướng để làm rõ lý do chọn phương pháp đề xuất.

CHƯƠNG 3:

DỮ LIỆU VÀ QUY TRÌNH GÁN NHÃN

3.1 Nguồn dữ liệu

Dữ liệu được thu thập từ các nền tảng mạng xã hội như TikTok và Facebook. Các mẫu dữ liệu được ưu tiên lấy từ nội dung có liên quan đến quảng cáo thực phẩm chức năng, thực phẩm bảo vệ sức khỏe, sản phẩm hỗ trợ sinh lý, xương khớp, tiểu đường, giảm cân, làm đẹp hoặc các nhóm sản phẩm sức khỏe phổ biến khác.

3.2 Quy trình thu thập dữ liệu

Quy trình thu thập dữ liệu gồm các bước chính:

1. Xác định từ khóa và nhóm sản phẩm cần thu thập.
2. Cào dữ liệu bài đăng hoặc video từ nền tảng mạng xã hội.
3. Trích xuất văn bản từ caption, mô tả, bình luận, phụ đề hoặc transcript.
4. Chuẩn hóa dữ liệu và loại bỏ mẫu trùng lặp.
5. Lưu trữ các trường thông tin cần thiết để phục vụ gán nhãn và truy vết.

3.3 Định dạng dữ liệu

Bảng 3.1. Định dạng dữ liệu đề xuất

Trường	Ý nghĩa
id	Mã định danh duy nhất của mẫu dữ liệu.
text	Nội dung văn bản đã trích xuất từ bài đăng, phụ đề hoặc mô tả.
source	Nền tảng hoặc nguồn thu thập.
posted_at	Thời gian đăng tải nếu có.
labels	Các nhãn được gán cho mẫu dữ liệu.
split	Tập dữ liệu tương ứng: train, validation hoặc test.

3.4 Bộ nhãn sử dụng

Bảng 3.2. Bộ nhãn phân loại dự kiến

Nhãn	Ý nghĩa
IS_ADS	Mẫu có bản chất là quảng cáo hoặc nội dung bán hàng.
EFFICACY_CLAIM	Có tuyên bố công dụng, hiệu quả hoặc lợi ích sức khỏe.
CURE_CLAIM	Có tuyên bố chữa bệnh, điều trị, thay thế thuốc hoặc khỏi bệnh.
AUTHORITY_REFERENCE	Có sử dụng hoặc gọi nhắc uy tín bác sĩ, bệnh viện, cơ quan, chuyên gia.
TESTIMONIAL	Có câu chuyện nhân chứng, phản hồi khách hàng, hành trình khỏi bệnh.
FEAR_URGENCY	Có yếu tố hù dọa, cảnh báo biến chứng, khan hiếm hoặc thúc ép hành động.
PRICE_PROMOTION	Có ưu đãi, giảm giá, khuyến mãi, cam kết hoàn tiền hoặc deal giới hạn.

3.5 Nguyên tắc gán nhãn

Mỗi mẫu được gán nhãn dựa trên nội dung thực tế thay vì chỉ dựa vào sự xuất hiện của từ khóa. Trường hợp một mẫu không phải quảng cáo nhưng có chứa thông tin sức khỏe chung, nhãn IS_ADS có thể bằng 0 trong khi các nhãn nội dung khác vẫn cần được xem xét tùy ngữ cảnh. Các mẫu giáo dục sức khỏe thông thường, không có dấu hiệu bán hàng hoặc thúc đẩy sử dụng sản phẩm, cần được gán nhãn thận trọng để tránh làm mô hình học sai.

3.6 Chia tập dữ liệu

Dữ liệu sau khi làm sạch được chia thành các tập huấn luyện, kiểm định và kiểm tra. Cần đảm bảo phân phối nhãn giữa các tập tương đối ổn định, đặc biệt với các nhãn ít xuất hiện như TESTIMONIAL hoặc FEAR_URGENCY.

CHƯƠNG 4:

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

4.1 Kiến trúc hệ thống

Hệ thống được thiết kế theo hướng pipeline đa module nhằm hỗ trợ phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng trên mạng xã hội. Sau giai đoạn thu thập và chuẩn hóa dữ liệu, các mô hình phát hiện được tổ chức thành những lớp xử lý độc lập, chạy song song để tạo điểm dự đoán riêng. Tầng hợp nhất ở cuối pipeline nhận kết quả từ từng lớp mô hình và tạo nhãn, xác suất, bằng chứng cùng điểm rủi ro tổng hợp. Cách thiết kế này giúp hệ thống dễ mở rộng khi cần bổ sung nguồn dữ liệu mới, mô hình mới hoặc nhóm tín hiệu rủi ro mới.


Về tổng thể, hệ thống gồm các lớp chức năng chính sau:

- **Lớp thu thập dữ liệu:** tiếp nhận bài đăng, video, metadata, đường dẫn nguồn và văn bản thô từ các nền tảng như TikTok hoặc Facebook.
- **Lớp xử lý và quản lý dữ liệu:** chuẩn hóa dữ liệu, loại bỏ trùng lặp, quản lý nhãn, chia tập train/validation/test và lưu phiên bản dataset.
- **Lớp rule-based detection:** đọc tập keyword, phát hiện cụm từ rủi ro, xác định nhãn gợi ý và lưu đoạn bằng chứng trong văn bản.
- **Lớp PhoBERT:** suy luận mô hình PhoBERT đã fine-tune cho phân loại đa nhãn và trả về `phobert_score` cho từng nhãn.
- **Lớp OCR:** trích xuất frame từ ảnh/video, nhận diện chữ nhúng và tạo `OCR_score` dựa trên nội dung chữ nhận diện được.
- **Lớp ASR:** trích xuất audio từ video, chuyển lời nói thành văn bản và tạo `ASR_score` từ nội dung transcript.

- **Lớp visual detection:** phát hiện các tín hiệu hình ảnh có rủi ro như áo blouse, ống nghe, phòng khám hoặc hình ảnh chuyên gia y tế và tạo `visual_score`.
- **Lớp hợp nhất và chấm điểm rủi ro:** kết hợp điểm từ các lớp chạy song song để tạo điểm rủi ro tổng hợp.
- **Lớp truy xuất và giải thích:** truy xuất quy định, nguyên tắc gán nhãn và bằng chứng liên quan để hỗ trợ sinh kết luận có giải thích.
- **Lớp API/Demo:** cung cấp chức năng dự đoán cho người dùng hoặc hệ thống bên ngoài, trả về nhãn, xác suất, bằng chứng và phân giải thích.

Luồng xử lý chính của hệ thống bắt đầu từ việc thu thập bài đăng hoặc video. Dữ liệu thô sau đó được chuẩn hóa và kiểm tra chất lượng trước khi đưa vào các lớp mô hình song song. Văn bản từ caption hoặc mô tả được đưa đồng thời vào rule-based detection và PhoBERT. Hình ảnh hoặc video được đưa đồng thời vào OCR, ASR và visual detection. Mỗi lớp trả về score, nhãn gợi ý và bằng chứng tương ứng; tầng fusion tiếp nhận các kết quả này để tạo nhãn dự đoán, xác suất cuối cùng và điểm rủi ro. Cuối cùng, hệ thống có thể sử dụng module RAG và LLM reasoning để sinh phần giải thích phục vụ rà soát thủ công.

Overall architecture of the functional food advertising violation detection system



Hình 4.1. Kiến trúc tổng thể của hệ thống phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng

4.2 Thiết kế UC

Thiết kế UC mô tả các chức năng chính mà người dùng hoặc thành phần bên ngoài có thể tương tác với hệ thống. Các tác nhân chính gồm người quản trị dữ liệu, người gán nhãn hoặc rà soát, người dùng demo/API và các module AI nội bộ của hệ thống. Danh sách use case chính gồm:


- **UC01 – Thu thập dữ liệu:** người quản trị dữ liệu thu thập bài đăng, video, metadata, đường dẫn nguồn và văn bản thô từ TikTok hoặc Facebook.
- **UC02 – Xử lý và chuẩn hóa dữ liệu:** người quản trị dữ liệu chuẩn hóa văn bản, kiểm tra duplicate, kiểm tra dữ liệu thiếu và chuẩn bị dữ liệu cho gán nhãn hoặc

huấn luyện.

- **UC03 – Quản lý và gán nhãn dữ liệu:** người gán nhãn xem mẫu dữ liệu, gán một hoặc nhiều nhãn, ghi chú bằng chứng và cập nhật trạng thái review.
- **UC04 – Chia tập và lưu phiên bản dataset:** người quản trị dữ liệu chia dữ liệu thành train, validation và test, lưu thông tin phiên bản dataset và thống kê phân phối nhãn.
- **UC05 – Phát hiện rủi ro bằng luật:** module rule-based đọc keyword, phát hiện cụm từ rủi ro, trả về nhãn gợi ý và evidence span trong văn bản.
- **UC06 – Huấn luyện mô hình PhoBERT:** người nghiên cứu huấn luyện PhoBERT trên tập train, chọn checkpoint tốt nhất và lưu mô hình.
- **UC07 – Suy luận văn bản bằng PhoBERT:** lớp PhoBERT dự đoán xác suất cho từng nhãn từ văn bản đầu vào.
- **UC08 – Phân tích ảnh và video:** các lớp OCR, ASR và visual detection chạy song song để nhận diện chữ, lời nói và tín hiệu hình ảnh rủi ro.
- **UC09 – Hợp nhất điểm rủi ro:** module fusion kết hợp phobert score, OCR score, ASR score, visual score và rule score để tạo risk score tổng hợp.
- **UC10 – Truy xuất quy định và sinh giải thích:** module RAG/LLM truy xuất quy định, nguyên tắc gán nhãn, bằng chứng liên quan và sinh phần giải thích cho kết quả dự đoán.
- **UC11 – Dự đoán qua API hoặc demo:** người dùng demo/API gửi văn bản hoặc metadata bài đăng tới endpoint dự đoán, nhận nhãn, xác suất, bằng chứng và giải thích.
- **UC12 – Xuất kết quả phục vụ rà soát:** người rà soát xuất file kết quả gồm dữ liệu, nhãn thật, nhãn dự đoán, xác suất, điểm rủi ro và ghi chú lỗi để kiểm tra thủ công.

4.2.1 Đặc tả UC01 – Thu thập dữ liệu

UC01 mô tả chức năng thu thập dữ liệu thô từ TikTok/Facebook thông qua Apify và lưu trữ kết quả trên Google Drive. Đây là use case đầu vào của toàn bộ pipeline, vì chất lượng dữ liệu thu thập ảnh hưởng trực tiếp đến các bước xử lý, gán nhãn và huấn luyện mô hình phía sau.



Hình 4.2. Use case UC01 – Thu thập dữ liệu

Bảng 4.1. Đặc tả use case UC01 – Thu thập dữ liệu

Thành phần	Nội dung
Mã use case	UC01
Tên use case	Thu thập dữ liệu

Thành phần	Nội dung
Tác nhân chính	Người quản trị dữ liệu
Tác nhân phụ	Apify, TikTok/Facebook, Google Drive
Mục tiêu	Thu thập bài đăng, video, metadata, source URL, file/video link và văn bản thô từ TikTok/Facebook thông qua Apify, sau đó lưu dữ liệu thô lên Google Drive để phục vụ xử lý, gán nhãn và huấn luyện mô hình.
Tiền điều kiện	Người quản trị dữ liệu đã xác định nền tảng, từ khóa, nhóm sản phẩm hoặc danh sách URL cần thu thập; tác vụ Apify đã sẵn sàng để chạy.
Hậu điều kiện	Dữ liệu thô được lưu trên Google Drive, bao gồm raw text, metadata, source URL, file/video link, nền tảng và định danh mẫu dữ liệu.
Luồng chính	Bước 1: Người quản trị dữ liệu cấu hình tác vụ Apify. Bước 2: Người quản trị nhập từ khóa, nhóm sản phẩm hoặc URL bài đăng/video. Bước 3: Apify truy xuất bài đăng/video từ nền tảng nguồn. Bước 4: Hệ thống nhận kết quả crawl từ Apify. Bước 5: Hệ thống trích xuất hoặc chuẩn hóa text thô, meta-data, source URL và file/video link. Bước 6: Hệ thống lưu dữ liệu thô lên Google Drive. Bước 7: Hệ thống trả về trạng thái thu thập thành công.

Thành phần	Nội dung
Luồng thay thế	Bước 1: Nếu URL không hợp lệ, bài đăng/video không truy cập được hoặc Apify trả lỗi, hệ thống ghi nhận lỗi và bỏ qua mẫu đó. Bước 2: Nếu dữ liệu đã tồn tại trên Google Drive, hệ thống đánh dấu trùng lặp để xử lý ở bước sau.
Dữ liệu đầu vào	Từ khóa, nhóm sản phẩm, URL bài đăng/video, nền tảng và cấu hình tác vụ Apify.
Dữ liệu đầu ra	Dữ liệu thô trên Google Drive gồm raw text, source URL, file/video link, platform, post/video id, thời gian thu thập và metadata liên quan.
Ngoại lệ	Apify lỗi, hết quota, URL lỗi, bài đăng/video bị xóa, nội dung bị giới hạn quyền truy cập, thiếu metadata hoặc không lưu được lên Google Drive.


Trong phạm vi đề tài, các UC liên quan đến dữ liệu và từng lớp xử lý được thiết kế theo hướng độc lập để có thể huấn luyện, suy luận và đánh giá riêng. Khi triển khai đầy đủ, các lớp PhoBERT, OCR, ASR, visual detection và rule-based detection không phụ thuộc tuần tự vào nhau mà cùng tạo đầu ra cho tầng fusion. Cách tổ chức này giúp hệ thống có thể bật/tắt từng nhánh xử lý và mở rộng thêm nguồn tín hiệu mới mà không làm thay đổi toàn bộ pipeline.

CHƯƠNG 5:

PHƯƠNG PHÁP ĐỀ XUẤT

5.1 Tổng quan kiến trúc hệ thống

Hệ thống được đề xuất theo pipeline đa phương thức gồm thu thập dữ liệu, tiền xử lý văn bản, OCR chữ trong ảnh/video, ASR lời nói, trích xuất tín hiệu hình ảnh, phân loại đa nhãn và hậu xử lý kết quả bằng luật hỗ trợ. Trong kiến trúc tổng thể, PhoBERT, OCR, ASR, visual detection và rule-based detection được xem là các nhánh xử lý song song; mỗi nhánh tạo score riêng trước khi tầng fusion tổng hợp kết quả cuối cùng. Phần thực nghiệm hiện tại tập trung minh họa nhánh PhoBERT cho phân loại đa nhãn văn bản; pipeline huấn luyện nhánh này được trình bày trong Hình 5.1.



Hình 5.1. Pipeline huấn luyện mô hình PhoBERT multi-label để phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng.

5.2 Tiền xử lý văn bản

Các bước tiền xử lý bao gồm chuẩn hóa Unicode, loại bỏ ký tự nhiễu không cần thiết, xử lý teencode, chuẩn hóa viết hoa/viết thường và tách dữ liệu theo đầu vào của mô hình. Đối với nội dung mạng xã hội, cần giữ lại một số ký hiệu đặc trưng như emoji, dấu chấm xen giữa chữ hoặc cách viết né tránh vì chúng có thể là tín hiệu lách luật.

5.3 Mô hình phân loại đa nhãn

Bài toán được xây dựng dưới dạng phân loại đa nhãn. Với mỗi văn bản đầu vào, mô hình dự đoán xác suất cho từng nhãn. Sau đó, mỗi nhãn được so sánh với ngưỡng riêng để quyết định nhãn cuối cùng.

5.3.1 Thử nghiệm và tối ưu mô hình PhoBERT cho phân loại đa nhãn

Trong thực nghiệm với dữ liệu văn bản, đề tài sử dụng PhoBERT-base-v2 làm encoder tiếng Việt và bổ sung classification head gồm 7 đầu ra sigmoid tương ứng với 7 nhãn. Mô hình được triển khai bằng lớp `AutoModelForSequenceClassification`. Tham số `problem_type` được đặt ở chế độ `multi_label_classification`. Cách thiết lập này phù hợp với bài toán vì một nội dung quảng cáo có thể đồng thời chứa nhiều dấu hiệu sai phạm, ví dụ vừa tuyên bố công dụng, vừa nhắc đến bác sĩ/chuyên gia, vừa kèm ưu đãi hoặc lời cam kết bán hàng.

Do dữ liệu có hiện tượng mất cân bằng, đặc biệt ở các nhãn hiếm, đề tài thử nghiệm thêm `weighted binary cross entropy`. Loss được cài đặt thông qua `BCEWithLogitsLoss` và `pos_weight`. Trọng số dương được tính dựa trên tỷ lệ âm/dương trong tập huấn luyện, sau đó làm mềm bằng căn bậc hai và giới hạn trong khoảng hợp lý. Cách này giúp mô hình chú ý hơn đến nhãn hiếm, nhưng nếu trọng số quá lớn thì dễ làm tăng `false positive`.

Quá trình thử nghiệm cũng cho thấy việc chọn checkpoint tốt nhất theo `eval_loss` không nhất thiết cho kết quả F1 tốt nhất trong bài toán phân loại đa nhãn mất cân bằng. Loss phản ánh mức độ khớp xác suất, nhưng chưa trực tiếp phản ánh chất lượng dự đoán sau khi áp threshold. Vì vậy, đề tài sử dụng chỉ số cân bằng giữa macro F1 và micro F1 để lựa chọn checkpoint:

$$F1_{balanced} = 0.5 \times F1_{macro} + 0.5 \times F1_{micro}$$

Chỉ số này giúp cân bằng giữa hiệu quả trên toàn bộ nhãn và hiệu quả tổng thể của mô hình.

Sau khi chọn checkpoint, threshold của từng nhãn được tune riêng trên tập validation thay vì dùng cố định 0.5. Tuy nhiên, do validation set nhỏ và một số nhãn có số mẫu dương thấp, threshold tự động có thể bị lệch theo một vài mẫu cụ thể. Vì vậy, threshold cuối cùng được chặn trong khoảng giá trị hợp lý theo từng nhãn để hạn chế overfit validation.

Ngoài ra, dữ liệu được chia lại theo `post_id` nhằm hạn chế leakage: các đoạn hoặc chunk thuộc cùng một bài đăng không được xuất hiện đồng thời trong train, validation và test. Cách chia này giúp đánh giá khách quan hơn so với split ngẫu nhiên, dù kết quả có thể thấp hơn do mô hình phải tổng quát hóa trên bài đăng mới.

Bảng 5.1. Tóm tắt các cấu hình thử nghiệm với mô hình PhoBERT

Thành phần	Cấu hình thử nghiệm	Mục tiêu	Nhận xét
Loss	Loss mặc định multi-label; BCEWithLogitsLoss với <code>pos_weight</code>	Xử lý mất cân bằng nhãn	Weighted loss giúp nhãn hiếm được chú ý hơn, nhưng cần làm mềm và clipping trọng số để tránh false positive.
Checkpoint	Chọn theo <code>eval_loss</code> ; chọn theo F1 sau threshold	Tìm checkpoint có khả năng phân loại tốt	<code>eval_loss</code> không luôn tương ứng với F1 tốt nhất trong bài toán đa nhãn.
Threshold	Threshold 0.5; auto threshold theo validation; threshold có chặn biên	Tối ưu quyết định nhãn cuối cùng	Threshold riêng theo nhãn hiệu quả hơn, nhưng cần chặn biên với nhãn hiếm.
Split dữ liệu	Split ngẫu nhiên; split theo <code>post_id</code>	Hạn chế leakage giữa các tập	Split theo <code>post_id</code> cho đánh giá khách quan hơn.

5.4 Điều chỉnh ngưỡng dự đoán

Thay vì sử dụng ngưỡng cố định 0.5 cho mọi nhãn, đề tài có thể tìm ngưỡng tốt nhất trên tập validation cho từng nhãn. Cách làm này đặc biệt hữu ích khi dữ liệu mất cân bằng hoặc một số nhãn khó học hơn các nhãn còn lại.

Bảng 5.2. Bảng ngưỡng dự đoán cho từng nhãn

Nhãn	Ngưỡng	Ghi chú
EFFICACY_CLAIM	0.57	Giữ theo threshold tự động trên validation.
CURE_CLAIM	0.73	Threshold cao hơn nhằm hạn chế false positive ở tuyên bố chữa bệnh.
AUTHORITY_REFERENCE	0.59	Giữ theo threshold tự động trên validation.
TESTIMONIAL	0.65	Threshold tự động thấp được chặn biên do support validation nhỏ.
FEAR_URGENCY	0.27	Threshold thấp để tăng recall cho nhãn hiếm.
PRICE_PROMOTION	0.60	Threshold tự động được chặn biên để tránh quá lệch validation.
IS_ADS	0.65	Threshold cuối cùng sau khi chặn biên.

5.5 Hậu xử lý và luật hỗ trợ

Bên cạnh dự đoán từ mô hình, có thể kết hợp các luật hỗ trợ nhằm phát hiện các cụm từ có rủi ro cao như “khỏi 100%”, “trị tận gốc”, “bác sĩ khuyên dùng”, hoặc các mẫu teencode. Tuy nhiên, luật từ khóa chỉ nên đóng vai trò hỗ trợ vì nếu dùng đơn độc sẽ dễ sinh false positive.

CHƯƠNG 6:

THỰC NGHIỆM VÀ ĐÁNH GIÁ

6.1 Thiết lập thực nghiệm

Thực nghiệm chính sử dụng mô hình PhoBERT-base-v2 được fine-tune cho bài toán phân loại đa nhãn bằng lớp `AutoModelForSequenceClassification`. Tham số `problem_type` được đặt ở chế độ `multi_label_classification`. Mô hình dự đoán 7 nhãn chính; danh sách nhãn và kết quả tương ứng được trình bày trong các bảng bên dưới. Checkpoint được chọn theo chỉ số F1 cân bằng giữa macro F1 và micro F1, sau đó threshold của từng nhãn được tune lần cuối trên validation set và chặn trong khoảng hợp lý.

6.2 Thống kê dữ liệu

Bảng 6.1. Thống kê số lượng mẫu theo tập dữ liệu

Tập dữ liệu	Số mẫu	Tỷ lệ
Train	<số mẫu>	<%>
Validation	<số mẫu>	<%>
Test	<số mẫu>	<%>

Bảng 6.2. Thống kê phân phối nhãn

Nhãn	Số mẫu dương	Tỷ lệ	Nhận xét
IS_ADS	<>	<>	<>
EFFICACY_CLAIM	<>	<>	<>
CURE_CLAIM	<>	<>	<>
AUTHORITY_REFERENCE	<>	<>	<>
TESTIMONIAL	<>	<>	<>
FEAR_URGENCY	<>	<>	<>
PRICE_PROMOTION	<>	<>	<>

6.3 Chỉ số đánh giá

Các chỉ số đánh giá gồm exact match accuracy, micro/macro precision, micro/macro recall và micro/macro F1. Với bài toán đa nhãn, macro F1 phản ánh tốt hơn hiệu quả trên các nhãn ít dữ liệu, trong khi micro F1 phản ánh hiệu quả tổng thể theo toàn bộ dự đoán.

6.4 Kết quả thực nghiệm

Bảng 6.3. Threshold cuối cùng dùng để đánh giá validation/test

Nhãn	Threshold
EFFICACY_CLAIM	0.57
CURE_CLAIM	0.73
AUTHORITY_REFERENCE	0.59
TESTIMONIAL	0.65
FEAR_URGENCY	0.27
PRICE_PROMOTION	0.60
IS_ADS	0.65

Bảng 6.4. Kết quả tổng quan trên validation và test

Tập	Exact match	Macro F1	Micro F1	Macro P	Macro R
Validation	0.6747	0.7522	0.8468	0.7191	0.8304
Test	0.6546	0.6413	0.8183	0.6115	0.6790

Bảng 6.5. Kết quả đánh giá theo từng nhãn trên tập test

Nhãn	P	R	F1	Support	Nhận xét
EFFICACY_CLAIM	0.7177	0.8812	0.7911	101	Recall cao, phù hợp với mục tiêu phát hiện claim công dụng.
CURE_CLAIM	0.8056	0.8286	0.8169	35	Kết quả ổn định dù support thấp hơn nhãn công dụng.
AUTHORITY_REFERENCE	0.7808	0.9344	0.8507	61	Nhãn đạt F1 cao nhất trong các nhãn nội dung rủi ro.
TESTIMONIAL	0.0000	0.0000	0.0000	4	Chưa học tốt do số mẫu dương rất ít.
FEAR_URGENCY	0.2857	0.4000	0.3333	5	Kết quả còn hạn chế do nhãn hiếm và biểu đạt đa dạng.
PRICE_PROMOTION	0.8333	0.7812	0.8065	32	Tín hiệu khuyến mãi tương đối rõ, F1 đạt mức tốt.
IS_ADS	0.8571	0.9273	0.8908	110	Nhãn quảng cáo tổng quát đạt kết quả tốt nhất.

Bảng 6.6. So sánh F1 theo từng nhãn trên validation và test

Nhãn	Val F1	Val support	Test F1	Test support
EFFICACY_CLAIM	0.8219	102	0.7911	101
CURE_CLAIM	0.8649	35	0.8169	35
AUTHORITY_REFERENCE	0.8550	61	0.8507	61
TESTIMONIAL	0.5714	4	0.0000	4
FEAR_URGENCY	0.4000	5	0.3333	5
PRICE_PROMOTION	0.8438	32	0.8065	32
IS_ADS	0.9083	109	0.8908	110

Trên tập test, mô hình đạt micro F1 là 0.8183 và macro F1 là 0.6413. Chênh lệch giữa micro F1 và macro F1 cho thấy mô hình hoạt động tốt trên các nhãn phổ biến, nhưng hiệu quả giảm ở các nhãn hiếm. Các nhãn quảng cáo, tham chiếu uy tín, tuyên bố chữa bệnh, khuyến mãi và tuyên bố công dụng đạt F1 tương đối ổn định. Ngược lại, TESTIMONIAL và FEAR_URGENCY còn hạn chế do số lượng mẫu dương trong validation/test rất thấp và cách biểu đạt trong dữ liệu mạng xã hội đa dạng.

6.5 Phân tích lỗi

Phân tích lỗi tập trung vào các nhóm mẫu bị nhầm lẫn thường gặp: nội dung giáo dục sức khỏe nhưng không bán hàng, quảng cáo ngụy trang dưới dạng chia sẻ cá nhân, câu chuyện bệnh nhân không nhắc trực tiếp tên sản phẩm, hoặc nội dung dùng ký tự đặc biệt để né kiểm duyệt. Với TESTIMONIAL, mô hình dễ bỏ sót các trường hợp kể chuyện khỏi bệnh gián tiếp hoặc testimonial xuất hiện dưới dạng bình luận, hình ảnh, video. Với FEAR_URGENCY, mô hình có thể nhầm giữa nội dung hù dọa bán hàng và cảnh báo sức khỏe trung lập.

6.6 Thảo luận

Kết quả cho thấy mô hình PhoBERT phù hợp với các nhãn có tín hiệu ngôn ngữ rõ và số lượng mẫu dương tương đối đủ. Các nhãn hiếm như TESTIMONIAL và FEAR_URGENCY cần

được cải thiện bằng cách bổ sung dữ liệu thật, tạo dữ liệu synthetic có kiểm soát, audit thủ công các mẫu false positive/false negative và hoàn thiện nguyên tắc gán nhãn. Ngoài ra, một phần tín hiệu testimonial hoặc hù dọa có thể nằm trong hình ảnh, video hoặc lời thoại, vì vậy các module OCR, ASR và nhận diện tín hiệu hình ảnh là cần thiết trong pipeline đa phương thức.

CHƯƠNG 7:

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã xây dựng hướng tiếp cận phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng trên mạng xã hội theo bài toán phân loại đa nhãn. Quy trình gồm thu thập dữ liệu, gán nhãn, huấn luyện mô hình, điều chỉnh ngưỡng và đánh giá kết quả trên từng nhóm dấu hiệu.

7.2 Ưu điểm

- Bộ nhãn bám sát các dạng vi phạm thường gặp trong quảng cáo thực phẩm chức năng.
- Hướng tiếp cận đa nhãn phù hợp với thực tế một quảng cáo có thể chứa nhiều dấu hiệu sai phạm.
- Quy trình có thể mở rộng sang dữ liệu hình ảnh, video và âm thanh.

7.3 Hạn chế

- Dữ liệu mạng xã hội có nhiều cách diễn đạt lách luật, gây khó khăn cho mô hình.
- Một số nhãn có thể bị mất cân bằng dữ liệu, làm giảm F1 macro.
- Giai đoạn hiện tại chủ yếu tập trung vào văn bản, chưa khai thác đầy đủ tín hiệu đa phương thức.

7.4 Hướng phát triển

- Mở rộng bộ dữ liệu bằng cách thu thập thêm mẫu từ nhiều nền tảng và nhóm sản phẩm khác nhau.

- Bổ sung OCR để phát hiện chữ nhúng trong ảnh hoặc video.
- Bổ sung ASR để phân tích lời thoại trong video quảng cáo.
- Kết hợp mô hình nhận diện hình ảnh nhằm phát hiện áo blouse, logo giả mạo hoặc bối cảnh y tế.
- Xây dựng giao diện hỗ trợ kiểm duyệt viên xem kết quả, lý do cảnh báo và bằng chứng liên quan.

TÀI LIỆU THAM KHẢO

- [1] Quốc hội, *Luật Quảng cáo 2012*, Việt Nam, 2012.
- [2] Chính phủ, *Nghị định 15/2018/NĐ-CP quy định chi tiết thi hành một số điều của Luật An toàn thực phẩm*, Việt Nam, 2018.
- [3] Chính phủ, *Nghị định 38/2021/NĐ-CP quy định xử phạt vi phạm hành chính trong lĩnh vực văn hóa và quảng cáo*, Việt Nam, 2021.