

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ PHẦN MỀM

BÁO CÁO ĐỒ ÁN MÔN HỌC
HỌC SÂU ỨNG DỤNG TRONG PHÁT TRIỂN PHẦN MỀM

PHÁT HIỆN SAI PHẠM TRONG QUẢNG CÁO THỰC
PHẨM CHỨC NĂNG TRÊN MẠNG XÃ HỘI



Giảng viên hướng dẫn: Đỗ Trọng Hợp

Sinh viên thực hiện: Hồ Nguyên Vũ

Mã số sinh viên: 23521805

Lớp: SE365.Q21

TP. HỒ CHÍ MINH, THÁNG 06 NĂM 2026

Mục lục

1	MỞ ĐẦU	1
1.1	Bối cảnh đề tài	1
1.2	Vấn đề nghiên cứu	1
1.3	Mục tiêu đề tài	2
1.4	Phạm vi nghiên cứu	3
1.5	Yêu cầu chức năng tổng quát	3
1.6	Đóng góp dự kiến	4
2	CƠ SỞ LÝ THUYẾT VÀ PHÁP LÝ	5
2.1	Tổng quan về quảng cáo thực phẩm chức năng	5
2.2	Cơ sở pháp lý liên quan	5
2.3	Các nhóm dấu hiệu rủi ro	6
2.4	Nền tảng xử lý ngôn ngữ tự nhiên	6
2.5	Nền tảng thị giác máy tính	7
2.6	Công cụ và framework sử dụng	7
2.7	Chỉ số đánh giá liên quan	10
2.8	Các hướng tiếp cận liên quan	11
3	DỮ LIỆU VÀ QUY TRÌNH GÁN NHÃN	12
3.1	Nguồn dữ liệu	12
3.1.1	Dữ liệu văn bản	12
3.1.2	Dữ liệu hình ảnh	12

3.2	Quy trình thu thập và xử lý dữ liệu	13
3.2.1	Dữ liệu văn bản	13
3.2.2	Dữ liệu hình ảnh	13
3.3	Định dạng dữ liệu	14
3.3.1	Dữ liệu văn bản	14
3.3.2	Dữ liệu hình ảnh	14
3.4	Bộ nhãn sử dụng	15
3.4.1	Bộ nhãn văn bản	15
3.4.2	Bộ nhãn hình ảnh	16
3.5	Nguyên tắc gán nhãn	16
3.5.1	Dữ liệu văn bản	16
3.5.2	Dữ liệu hình ảnh	16
3.6	Chia tập dữ liệu	17
3.6.1	Dữ liệu văn bản	17
3.6.2	Dữ liệu hình ảnh	17
4	PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	18
4.1	Kiến trúc hệ thống	18
4.2	Thiết kế UC	20
4.2.1	Đặc tả UC01 – Thu thập dữ liệu	21
4.2.2	Đặc tả UC02 – Xử lý và chuẩn hóa dữ liệu	24
4.2.3	Đặc tả UC03 – Quản lý và gán nhãn dữ liệu	29
4.2.4	Đặc tả UC04 – Chia tập và lưu phiên bản dataset	34
4.2.5	Đặc tả UC05 – Huấn luyện mô hình PhoBERT	40
4.2.6	Đặc tả UC06 – Huấn luyện mô hình YOLO v11	47
5	PHƯƠNG PHÁP ĐỀ XUẤT	56
5.1	Tổng quan phương pháp	56

5.2	Nhánh phân tích văn bản bằng PhoBERT	56
5.2.1	Biểu diễn bài toán	56
5.2.2	Tiền xử lý văn bản	57
5.2.3	Huấn luyện và tối ưu	57
5.3	Nhánh phát hiện hình ảnh bằng YOLO	59
5.3.1	Mục tiêu của nhánh hình ảnh	59
5.3.2	Nhãn và vai trò	59
5.3.3	Công nghệ và cấu hình huấn luyện	59
5.3.4	Đầu ra của nhánh YOLO	60
5.4	OCR, ASR và rule-based detection	62
5.5	Hợp nhất điểm rủi ro	62
5.6	Nguyên tắc diễn giải kết quả	62
6	THỰC NGHIỆM VÀ ĐÁNH GIÁ	63
6.1	Thiết lập thực nghiệm đa phương thức	63
6.2	Dữ liệu và chỉ số đánh giá	63
6.2.1	Dữ liệu văn bản	63
6.2.2	Dữ liệu hình ảnh	64
6.2.3	Chỉ số đánh giá	64
6.3	Kết quả nhánh văn bản PhoBERT	66
6.3.1	Threshold và kết quả tổng quan	66
6.3.2	Kết quả theo nhãn	67
6.4	Kết quả nhánh hình ảnh YOLO	68
6.4.1	Kết quả tổng thể	68
6.4.2	Kết quả theo từng lớp	69
6.4.3	Trực quan hóa kết quả YOLO	70
6.4.4	Phân tích kết quả YOLO	71

6.5	Thảo luận chung	72
6.6	Hạn chế và hướng cải thiện	72
7	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	74
7.1	Kết luận	74
7.2	Ưu điểm	74
7.3	Hạn chế	75
7.4	Hướng phát triển	75
7.5	Kết luận chung	76
	TÀI LIỆU THAM KHẢO	77

Danh sách bảng

2.1	Nhóm dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng	6
2.2	Ưu điểm, nhược điểm và lý do sử dụng các công cụ trong đề tài	7
3.1	Định dạng dữ liệu văn bản đề xuất	14
3.2	Định dạng dữ liệu hình ảnh đề xuất	14
3.3	Bộ nhãn phân loại văn bản	15
3.4	Bộ nhãn hình ảnh dùng cho object detection	16
4.1	Đặc tả use case UC01 – Thu thập dữ liệu	22
4.2	Đặc tả use case UC02 – Xử lý và chuẩn hóa dữ liệu	25
4.3	Đặc tả use case UC03 – Quản lý và gán nhãn dữ liệu	30
4.4	Đặc tả use case UC04 – Chia tập và lưu phiên bản dataset	35
4.5	Đặc tả use case UC05 – Huấn luyện mô hình PhoBERT	41
4.6	Đặc tả use case UC06 – Huấn luyện mô hình YOLO v11	48
5.1	Tóm tắt pipeline nhánh PhoBERT	58
5.2	Cấu hình huấn luyện chính của nhánh YOLO	60
6.1	Thống kê số lượng mẫu văn bản theo tập dữ liệu	63
6.2	Thống kê phân phối nhãn văn bản	64
6.3	Threshold cuối cùng dùng để đánh giá validation/test	66
6.4	Kết quả tổng quan của PhoBERT trên validation và test	66
6.5	Kết quả PhoBERT theo từng nhãn trên tập test	67
6.6	Kết quả tổng thể của YOLO11m trên test set	68

6.7	Kết quả YOLO11m theo từng lớp trên test set	69
6.8	mAP50-95 theo từng lớp của YOLO11m	69

Danh sách hình vẽ

4.1	Kiến trúc tổng thể của hệ thống phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng	20
4.2	Use case UC01 – Thu thập dữ liệu	22
4.3	Use case UC02 – Xử lý và chuẩn hóa dữ liệu	25
4.4	Use case UC03 – Quản lý và gán nhãn dữ liệu	30
4.5	Use case UC04 – Chia tập và lưu phiên bản dataset	35
4.6	Use case UC05 – Huấn luyện mô hình PhoBERT	41
4.7	Use case UC06 – Huấn luyện mô hình YOLO v11	48
6.1	Ma trận nhầm lẫn của YOLO11m trên tập test	70
6.2	Đường cong PR và F1 của YOLO11m trên tập test	70
6.3	Đường cong Precision và Recall của YOLO11m trên tập test	71

CHƯƠNG 1:

MỞ ĐẦU

1.1 Bối cảnh đề tài

Sự phát triển của các nền tảng mạng xã hội như Facebook, TikTok và các kênh nội dung ngắn đã làm thay đổi đáng kể cách sản phẩm thực phẩm chức năng, thực phẩm bảo vệ sức khỏe được quảng bá đến người tiêu dùng. Nội dung quảng cáo hiện nay thường kết hợp nhiều dạng dữ liệu: văn bản bài đăng, phụ đề, chữ chèn trong ảnh, lời thoại trong video, hình ảnh chuyên gia, logo tổ chức, phản hồi người dùng và các hình thức khuyến mãi có tính lan truyền cao. Đặc điểm này giúp quảng cáo tiếp cận người dùng nhanh hơn, nhưng cũng làm cho quá trình rà soát thủ công trở nên khó khăn hơn.

Trong thực tế, một số nội dung quảng cáo thực phẩm chức năng có dấu hiệu thổi phồng công dụng, gây hiểu nhầm về khả năng điều trị bệnh, lợi dụng hình ảnh hoặc uy tín của bác sĩ, cơ sở y tế, cơ quan nhà nước, báo chí, hoặc khai thác tâm lý lo sợ của người tiêu dùng. Các dấu hiệu này có thể xuất hiện trong văn bản, chữ OCR trên ảnh/video, lời nói trong video hoặc các đối tượng hình ảnh như áo blouse, ống nghe và logo. Vì vậy, một hệ thống hỗ trợ rà soát cần được thiết kế theo hướng đa phương thức thay vì chỉ dựa trên một nguồn tín hiệu đơn lẻ.

1.2 Vấn đề nghiên cứu

Bài toán nghiên cứu của đề tài là xây dựng một pipeline hỗ trợ phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng trên mạng xã hội. Hệ thống không nhằm thay thế kết luận pháp lý của cơ quan chức năng hoặc người rà soát chuyên môn, mà đóng vai trò như công cụ hỗ trợ phát hiện sớm, ưu tiên kiểm tra và cung cấp bằng chứng cho các mẫu quảng cáo có rủi ro cao.

Trong pipeline đề xuất, các nhánh xử lý như PhoBERT, YOLO, OCR, ASR, rule-based detection và tổng hợp nhất rủi ro được xem là các thành phần có vai trò bổ sung cho nhau. PhoBERT tập trung vào tín hiệu ngôn ngữ trong văn bản; YOLO phát hiện các dấu hiệu hình ảnh liên quan đến bối cảnh y tế hoặc mạo danh uy tín; OCR và ASR chuyển nội dung chữ/giọng nói thành tín hiệu văn bản; rule-based detection hỗ trợ nhận diện các mẫu biểu đạt rủi ro rõ ràng. Kết quả cuối cùng chỉ nên được diễn giải sau khi tổng hợp nhiều nguồn tín hiệu và đối chiếu với ngữ cảnh.

1.3 Mục tiêu đề tài

Đề tài hướng đến các mục tiêu chính sau:

- Xây dựng quy trình thu thập, chuẩn hóa và quản lý dữ liệu quảng cáo thực phẩm chức năng từ mạng xã hội, bao gồm văn bản, hình ảnh, video, metadata và thông tin nguồn.
- Chuẩn hóa bộ nhãn phục vụ phát hiện dấu hiệu rủi ro trong văn bản và hình ảnh, trong đó các nhãn được định nghĩa theo vai trò hỗ trợ rà soát thay vì kết luận vi phạm tuyệt đối.
- Xây dựng các nhánh phát hiện độc lập gồm PhoBERT cho phân loại đa nhãn văn bản, YOLO cho phát hiện đối tượng hình ảnh, OCR/ASR cho trích xuất nội dung từ ảnh/video và rule-based detection cho các mẫu tín hiệu rõ.
- Thiết kế cơ chế hợp nhất điểm từ nhiều nhánh để tạo nhãn gợi ý, xác suất, bằng chứng và điểm rủi ro tổng hợp.
- Đánh giá từng nhánh bằng chỉ số phù hợp, phân tích lỗi và chỉ ra hạn chế để phục vụ mở rộng dữ liệu, cải thiện mô hình và hoàn thiện pipeline trong các phiên bản sau.

1.4 Phạm vi nghiên cứu

Phạm vi nghiên cứu hiện tại tập trung vào phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng, thực phẩm bảo vệ sức khỏe trên mạng xã hội. Dữ liệu đầu vào bao gồm văn bản bài đăng, caption, phụ đề, chữ OCR trong ảnh/video, lời nói được chuyển thành văn bản bằng ASR, frame hình ảnh và metadata liên quan.

Ở nhánh văn bản, đề tài sử dụng bảy nhãn: quảng cáo, tuyên bố công dụng, tuyên bố chữa bệnh, tham chiếu uy tín, nhân chứng, hù dọa/thúc ép và khuyến mãi. Ở nhánh hình ảnh, đề tài tập trung vào các đối tượng Lab-coat, logo, stethoscope và Shirt; trong đó Shirt là lớp phụ/đối chứng nhằm giảm nhầm lẫn với áo blouse y tế, không phải lớp vi phạm chính.

Đầu ra của hệ thống là nhãn gợi ý, xác suất, bằng chứng và điểm rủi ro tổng hợp. Đề tài không đưa ra kết luận pháp lý cuối cùng về hành vi vi phạm, mà cung cấp cơ sở hỗ trợ người rà soát đánh giá sâu hơn.

1.5 Yêu cầu chức năng tổng quát

Hệ thống được thiết kế theo kiến trúc module. Các yêu cầu chức năng chính gồm:

- Thu thập và lưu trữ dữ liệu thô từ mạng xã hội, bao gồm văn bản, ảnh, video, metadata và đường dẫn nguồn.
- Chuẩn hóa dữ liệu, kiểm tra trùng lặp, quản lý nhãn và chia tập train/validation/test có kiểm soát leakage.
- Phân tích văn bản bằng PhoBERT để dự đoán các nhãn rủi ro ở mức nội dung ngôn ngữ.
- Phân tích hình ảnh bằng YOLO để phát hiện các đối tượng tạo bối cảnh y tế hoặc dấu hiệu mạo danh uy tín.
- Trích xuất chữ trong ảnh/video bằng OCR và lời nói trong video bằng ASR để bổ

sung tín hiệu văn bản.

- Áp dụng rule-based detection để nhận diện các mẫu từ khóa hoặc biểu thức rủi ro rõ ràng.
- Hợp nhất các điểm dự đoán thành kết quả tổng hợp có bằng chứng và có thể phục vụ rà soát thủ công.

1.6 Đóng góp dự kiến

Đóng góp dự kiến của đề tài gồm:

- Một quy trình dữ liệu có thể tái lập cho bài toán phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng trên mạng xã hội.
- Bộ nhãn văn bản và hình ảnh được mô tả rõ vai trò, phù hợp với cách tiếp cận hỗ trợ rà soát đa phương thức.
- Pipeline gồm các nhánh PhoBERT, YOLO, OCR, ASR, rule-based detection và fusion/risk scoring.
- Kết quả thực nghiệm bước đầu cho cả nhánh văn bản và nhánh hình ảnh, kèm phân tích metric, hạn chế và hướng cải thiện.
- Cách diễn giải kết quả thận trọng, nhấn mạnh vai trò hỗ trợ phát hiện dấu hiệu rủi ro thay vì khẳng định vi phạm pháp lý.

CHƯƠNG 2:

CƠ SỞ LÝ THUYẾT VÀ PHÁP LÝ

2.1 Tổng quan về quảng cáo thực phẩm chức năng

Thực phẩm chức năng và thực phẩm bảo vệ sức khỏe là nhóm sản phẩm có liên quan trực tiếp đến nhận thức sức khỏe của người tiêu dùng. Vì vậy, nội dung quảng cáo cho nhóm sản phẩm này cần được kiểm soát thận trọng, đặc biệt với các thông tin có thể làm người dùng hiểu nhầm rằng sản phẩm có tác dụng như thuốc chữa bệnh.

Trên mạng xã hội, quảng cáo thường không chỉ xuất hiện dưới dạng văn bản thuần. Một mẫu quảng cáo có thể kết hợp caption, video, chữ chèn trong poster, lời thoại, hình ảnh người mặc áo blouse, ống nghe, logo tổ chức hoặc lời kể của người dùng. Do đó, việc phát hiện rủi ro cần dựa trên nhiều nguồn tín hiệu và cần tách bạch giữa phát hiện dấu hiệu với kết luận pháp lý cuối cùng.

2.2 Cơ sở pháp lý liên quan

Báo cáo sử dụng các quy định pháp lý như cơ sở định hướng cho việc xây dựng nhóm dấu hiệu rủi ro. Các văn bản thường được tham chiếu trong bối cảnh quảng cáo thực phẩm và thực phẩm bảo vệ sức khỏe gồm Luật Quảng cáo 2012, Nghị định 15/2018/NĐ-CP, Nghị định 38/2021/NĐ-CP và các văn bản cập nhật liên quan đến quản lý quảng cáo thực phẩm bảo vệ sức khỏe.

Trong phạm vi đề tài, các quy định này không được mã hóa trực tiếp thành kết luận vi phạm. Thay vào đó, chúng được dùng để xác định các nhóm tín hiệu cần rà soát như tuyên bố chữa bệnh, thổi phồng công dụng, lợi dụng uy tín chuyên gia/cơ quan hoặc thiếu căn cứ trong nội dung quảng cáo.

2.3 Các nhóm dấu hiệu rủi ro

Bảng 2.1. Nhóm dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng

Nhóm dấu hiệu	Mô tả ngắn
Tuyên bố công dụng quá mức	Nội dung nhấn mạnh hiệu quả sức khỏe, cải thiện bệnh lý hoặc cam kết kết quả theo cách dễ gây hiểu nhầm.
Tuyên bố chữa bệnh	Gán cho sản phẩm vai trò điều trị, thay thế thuốc hoặc chữa khỏi bệnh.
Lợi dụng uy tín	Sử dụng hoặc gọi nhắc bác sĩ, chuyên gia, bệnh viện, cơ quan, truyền thông, logo hoặc biểu tượng uy tín để tạo niềm tin.
Nhân chứng và trải nghiệm cá nhân	Dùng câu chuyện khỏi bệnh, phản hồi khách hàng, hình ảnh trước–sau hoặc lời kể cá nhân để tạo bằng chứng cảm tính.
Hù dọa và thúc ép hành động	Tạo áp lực bằng nguy cơ sức khỏe, khan hiếm giả, khuyến mãi giới hạn hoặc lời kêu gọi mua ngay.
Dấu hiệu hình ảnh y tế	Sử dụng áo blouse, ống nghe, bối cảnh y khoa hoặc logo để tăng cảm giác đáng tin cậy của quảng cáo.

2.4 Nền tảng xử lý ngôn ngữ tự nhiên

Bài toán văn bản được mô hình hóa theo hướng phân loại đa nhãn vì một mẫu quảng cáo có thể đồng thời chứa nhiều dấu hiệu rủi ro. Với mỗi mẫu, mô hình dự đoán xác suất cho từng nhãn và kết quả sau threshold được dùng như một nguồn tín hiệu trong tầng hợp nhất.

PhoBERT-base-v2 được sử dụng như encoder tiếng Việt cho nhánh văn bản. Mô hình transformer này phù hợp với dữ liệu tiếng Việt vì có khả năng biểu diễn ngữ cảnh tốt hơn

các phương pháp dựa trên từ khóa đơn giản. Tuy nhiên, hiệu quả của PhoBERT vẫn phụ thuộc vào chất lượng dữ liệu gán nhãn, mức cân bằng giữa các nhãn và cách chọn threshold sau huấn luyện.

2.5 Nền tảng thị giác máy tính

Ở nhánh hình ảnh, bài toán được xây dựng dưới dạng object detection. Mục tiêu không phải phân loại toàn bộ ảnh là vi phạm hay không vi phạm, mà là phát hiện các đối tượng có thể đóng vai trò dấu hiệu rủi ro trong ngữ cảnh quảng cáo. Các đối tượng như áo blouse trắng, logo và ống nghe y tế có thể làm tăng mức độ nghi ngờ khi xuất hiện cùng nội dung văn bản, OCR hoặc rule-based tương ứng.

YOLO là họ mô hình phát hiện đối tượng một giai đoạn, có khả năng dự đoán bounding box và lớp đối tượng trong ảnh với tốc độ suy luận tương đối nhanh. Trong đề tài, YOLO được dùng để tạo `visual_score` và bằng chứng hình ảnh cho tầng hợp nhất, không tự đưa ra kết luận pháp lý độc lập.

2.6 Công cụ và framework sử dụng

Các công cụ và framework được lựa chọn nhằm phục vụ toàn bộ pipeline, từ thu thập dữ liệu, tiền xử lý, gán nhãn, huấn luyện mô hình đến đánh giá và hợp nhất kết quả. Bảng 2.2 tóm tắt ưu điểm, nhược điểm và lý do sử dụng của từng nhóm công cụ trong phạm vi đề tài.

Bảng 2.2. Ưu điểm, nhược điểm và lý do sử dụng các công cụ trong đề tài

Công cụ / framework	Ưu điểm	Nhược điểm	Lý do sử dụng
Google Colab và GPU Tesla T4	Dễ thiết lập, hỗ trợ GPU, phù hợp với thử nghiệm học sâu trong môi trường notebook.	Thời gian phiên chạy, bộ nhớ và loại GPU có thể thay đổi; phụ thuộc kết nối mạng và tài nguyên được cấp phát.	Dùng để huấn luyện nhanh PhoBERT và YOLO mà không cần cấu hình máy cục bộ mạnh.

Công cụ / framework	Ưu điểm	Nhược điểm	Lý do sử dụng
Python	Hệ sinh thái thư viện phong phú, cú pháp dễ đọc, thuận tiện cho xử lý dữ liệu và thử nghiệm mô hình.	Tốc độ thực thi thuần không cao nếu không dùng thư viện tối ưu; dễ phát sinh lỗi môi trường nếu quản lý package chưa tốt.	Là ngôn ngữ chính để xây dựng pipeline xử lý dữ liệu, huấn luyện, đánh giá và xuất kết quả.
Pandas và NumPy	Mạnh trong xử lý dữ liệu bảng, thống kê, lọc mẫu, tính phân phối nhân và thao tác ma trận.	Có thể tốn bộ nhớ với dữ liệu lớn; cần kiểm soát kiểu dữ liệu khi đọc/ghi CSV.	Phù hợp với dữ liệu gán nhãn dạng bảng và các bước thống kê trước khi huấn luyện.
CSV và JSON	Đơn giản, dễ đọc, dễ kiểm tra thủ công; tương thích với nhiều công cụ phân tích.	CSV không ràng buộc schema chặt; JSON không tối ưu cho dữ liệu bảng lớn.	CSV dùng cho dữ liệu gán nhãn và kết quả dự đoán; JSON dùng cho cấu hình, threshold, danh sách nhãn và metadata.
PyTorch	Linh hoạt, hỗ trợ GPU tốt, tương thích trực tiếp với Transformers và các mô hình học sâu.	Cần hiểu tensor, device và quản lý bộ nhớ GPU; lỗi CUDA có thể khó xử lý với người mới.	Là nền tảng huấn luyện và suy luận cho các mô hình học sâu trong đề tài.
Hugging Face Transformers	Cung cấp API chuẩn cho tokenizer, mô hình, Trainer, checkpoint và callback; giảm khối lượng code tự viết.	Tùy biến sâu đôi khi cần hiểu rõ cơ chế Trainer; phiên bản thư viện có thể thay đổi tham số cấu hình.	Dùng để fine-tune PhoBERT cho bài toán phân loại đa nhãn tiếng Việt.
PhoBERT-base-v2	Được tiền huấn luyện cho tiếng Việt, biểu diễn ngữ cảnh tốt hơn phương pháp từ khóa đơn giản.	Phụ thuộc chất lượng dữ liệu gán nhãn; cần GPU để huấn luyện hiệu quả; có thể khó với nhãn hiếm.	Phù hợp với bài toán phát hiện dấu hiệu rủi ro trong văn bản quảng cáo tiếng Việt.

Công cụ / framework	Ưu điểm	Nhược điểm	Lý do sử dụng
Hugging Face Datasets	Tích hợp tốt với Transformers, hỗ trợ map/tokenization theo batch, giúp pipeline huấn luyện gọn hơn.	Với dữ liệu nhỏ, việc chuyển đổi từ DataFrame sang Dataset tạo thêm một bước xử lý.	Chuẩn hóa dữ liệu đầu vào cho Trainer và giảm lỗi trong quá trình batch-ing/tokenization.
Scikit-learn	Cung cấp các metric ổn định như precision, recall, macro F1, micro F1 và classification report.	Chủ yếu phục vụ xử lý/đánh giá trên CPU, không phải framework huấn luyện mô hình deep learning.	Dùng để đánh giá nhánh PhoBERT và phân tích hiệu quả theo từng nhãn.
Weighted loss và early stopping	Giúp xử lý mất cân bằng nhãn và giảm nguy cơ overfit khi validation không cải thiện.	Nếu trọng số quá lớn có thể tăng false positive; early stopping phụ thuộc độ đại diện của validation set.	Cần thiết vì dữ liệu văn bản có các nhãn hiếm như TESTIMONIAL và FEAR_URGENCY.
Roboflow	Thuận tiện cho quản lý dataset hình ảnh, gán nhãn bounding box, versioning và export YOLO format.	Phụ thuộc nền tảng bên ngoài; cần kiểm tra kỹ annotation và cảnh báo khi có lỗi định dạng box/segmentation.	Dùng để quản lý dataset doctor-and-medical, version 7, phục vụ huấn luyện YOLO.
Ultralytics YOLO	Cài đặt gọn, hỗ trợ huấn luyện/đánh giá object detection, xuất metric như Precision, Recall, mAP50 và mAP50-95.	Cần dữ liệu bounding box nhất quán; kết quả chỉ phát hiện đối tượng, không tự hiểu ngữ cảnh pháp lý.	Dùng cho nhánh phát hiện hình ảnh rủi ro như Lab-coat, logo và stethoscope.
yt-dlp và FFmpeg	Hỗ trợ tải media và trích frame/audio linh hoạt; phổ biến trong xử lý video.	Có thể lỗi với URL bị hạn chế quyền truy cập; cần kiểm soát dung lượng file và chất lượng frame/audio.	Dùng trong bước thu thập media, cắt video thành frame và chuẩn bị dữ liệu cho OCR/ASR/YOLO.

Công cụ / framework	Ưu điểm	Nhược điểm	Lý do sử dụng
OCR	Trích xuất chữ trong ảnh hoặc frame video, bổ sung tín hiệu văn bản ngoài caption.	Dễ sai với ảnh mờ, chữ nhỏ, font lạ, nền phức tạp hoặc chữ bị che khuất.	Cần thiết vì nhiều quảng cáo đưa claim hoặc cảnh báo vào poster/video thay vì caption.
ASR	Chuyển lời nói trong video thành văn bản, giúp phát hiện tuyên bố rủi ro trong audio.	Phụ thuộc chất lượng âm thanh, giọng nói, tiếng ồn và khả năng nhận dạng tiếng Việt.	Dùng để bổ sung tín hiệu từ lời thoại, đặc biệt với video quảng cáo không có caption đầy đủ.
Rule-based detection	Dễ giải thích, kiểm soát được keyword/evidence, phù hợp với các mẫu rủi ro rõ ràng.	Kém linh hoạt với cách diễn đạt mới, teencode hoặc nội dung né kiểm duyệt.	Dùng như nhánh hỗ trợ nhằm tăng khả năng giải thích và bổ sung bằng chứng cho tầng fusion.
Fusion/risk scoring	Cho phép tổng hợp score từ PhoBERT, YOLO, OCR, ASR và rule-based detection.	Cần hiệu chỉnh trọng số hoặc luật tổng hợp; nếu thiết kế chưa tốt có thể làm tăng false positive.	Phù hợp với mục tiêu hệ thống đa phương thức, trong đó mỗi nhánh chỉ đóng góp một phần bằng chứng.

2.7 Chỉ số đánh giá liên quan

Với phân loại đa nhãn văn bản, các chỉ số thường dùng gồm exact match accuracy, precision, recall, macro F1 và micro F1. Macro F1 phản ánh tốt hơn hiệu quả trên các nhãn ít dữ liệu, trong khi micro F1 phản ánh hiệu quả tổng thể theo toàn bộ dự đoán.

Với object detection, Precision cho biết tỷ lệ dự đoán đúng trong các đối tượng mô hình phát hiện, Recall cho biết tỷ lệ đối tượng thật được phát hiện, mAP50 đo trung bình độ chính xác tại ngưỡng IoU 0.5, còn mAP50-95 đo trung bình trên nhiều ngưỡng IoU từ 0.5 đến 0.95. mAP50-95 thường khắt khe hơn vì đánh giá cả khả năng định vị bounding box

chính xác.

2.8 Các hướng tiếp cận liên quan

Các hướng tiếp cận phổ biến gồm rule-based detection, học máy truyền thống, mô hình ngôn ngữ tiếng Việt, object detection và hệ thống đa phương thức. Rule-based detection dễ giải thích nhưng kém linh hoạt với cách viết lách luật. Mô hình ngôn ngữ học được ngữ cảnh tốt hơn nhưng có thể bỏ sót tín hiệu nằm trong ảnh hoặc video. Object detection bổ sung bằng chứng thị giác nhưng không đủ để kết luận khi thiếu ngữ cảnh văn bản. Vì vậy, đề tài lựa chọn hướng kết hợp nhiều nhánh và hợp nhất điểm rủi ro ở giai đoạn sau.

CHƯƠNG 3:

DỮ LIỆU VÀ QUY TRÌNH GÁN NHÃN

3.1 Nguồn dữ liệu

3.1.1 Dữ liệu văn bản

Dữ liệu văn bản được thu thập từ các nền tảng mạng xã hội như TikTok và Facebook, ưu tiên các nội dung liên quan đến quảng cáo thực phẩm chức năng, thực phẩm bảo vệ sức khỏe và các nhóm sản phẩm sức khỏe phổ biến. Nguồn văn bản bao gồm caption, mô tả bài đăng, bình luận, phụ đề, transcript và nội dung OCR/ASR được trích xuất từ ảnh hoặc video.

Mỗi mẫu văn bản cần được lưu kèm thông tin nguồn, thời điểm thu thập nếu có, định danh bài đăng hoặc video và metadata cần thiết. Các trường này giúp truy vết dữ liệu, kiểm tra trùng lặp và hạn chế leakage khi chia tập.

3.1.2 Dữ liệu hình ảnh

Dữ liệu hình ảnh bao gồm ảnh trong bài đăng, frame được cắt từ video và bộ dữ liệu hình ảnh được quản lý trên Roboflow. Trong phiên bản thực nghiệm hiện tại, dataset hình ảnh sử dụng workspace Roboflow với tên `doctor-and-medical`, version 7 và export theo định dạng YOLO. Dữ liệu tập trung vào các đối tượng có thể gợi ý bối cảnh y tế hoặc dấu hiệu mạo danh/lợi dụng uy tín trong quảng cáo.

Các frame trích từ video cần được lọc để giảm trùng lặp, ví dụ chỉ giữ các frame có mức khác biệt đủ lớn so với frame liền trước. Cách làm này giúp giảm số lượng ảnh gần giống nhau và hạn chế nguy cơ mô hình học lệch theo các frame lặp.

3.2 Quy trình thu thập và xử lý dữ liệu

3.2.1 Dữ liệu văn bản

Quy trình dữ liệu văn bản gồm các bước chính:

1. Xác định từ khóa, nhóm sản phẩm và danh sách URL cần thu thập.
2. Thu thập bài đăng, caption, mô tả, bình luận, phụ đề hoặc transcript từ nền tảng nguồn.
3. Chuẩn hóa Unicode, loại bỏ mẫu rỗng, kiểm tra trùng lặp và gán `post_id`.
4. Gán nhãn đa nhãn theo nội dung thực tế và lưu evidence nếu có.
5. Chia dữ liệu thành train, validation và test theo quy tắc hạn chế leakage.

3.2.2 Dữ liệu hình ảnh

Quy trình dữ liệu hình ảnh gồm các bước chính:

1. Tải ảnh hoặc video từ các đường dẫn media hợp lệ bằng công cụ phù hợp.
2. Cắt video thành frame và lọc các frame gần trùng lặp.
3. Đưa ảnh/frame vào Roboflow để gán nhãn đối tượng bằng bounding box.
4. Review thủ công các nhãn để nhầm lẫn như Lab-coat và Shirt.
5. Export dataset version 7 theo YOLO format để huấn luyện bằng Ultralytics YOLO.

3.3 Định dạng dữ liệu

3.3.1 Dữ liệu văn bản

Bảng 3.1. Định dạng dữ liệu văn bản đề xuất

Trường	Ý nghĩa
id	Mã định danh duy nhất của mẫu dữ liệu.
post_id	Mã bài đăng hoặc video gốc, dùng để hạn chế leakage khi chia tập.
text	Nội dung văn bản đã trích xuất từ caption, mô tả, phụ đề, OCR hoặc ASR.
source	Nền tảng hoặc nguồn thu thập dữ liệu.
labels	Các nhãn văn bản được gán cho mẫu.
evidence	Cụm từ hoặc đoạn văn bản làm bằng chứng cho nhãn nếu có.
split	Tập dữ liệu tương ứng: train, validation hoặc test.

3.3.2 Dữ liệu hình ảnh

Bảng 3.2. Định dạng dữ liệu hình ảnh đề xuất

Trường	Ý nghĩa
image_id	Mã định danh duy nhất của ảnh hoặc frame.
post_id	Mã bài đăng, video hoặc media gốc dùng để kiểm soát trùng lặp.
frame_path	Đường dẫn tới ảnh hoặc frame đã lưu.
source_media	Đường dẫn hoặc mã media gốc.
labels	Các nhãn đối tượng được gán trong ảnh/frame.
annotation	Thông tin bounding box theo định dạng YOLO hoặc định dạng trung gian từ Roboflow.
split	Tập dữ liệu tương ứng: train, validation hoặc test.

3.4 Bộ nhãn sử dụng

3.4.1 Bộ nhãn văn bản

Bảng 3.3. Bộ nhãn phân loại văn bản

Nhãn	Ý nghĩa
IS_ADS	Nội dung có bản chất quảng cáo hoặc bán hàng.
EFFICACY_CLAIM	Có tuyên bố công dụng, hiệu quả hoặc lợi ích sức khỏe.
CURE_CLAIM	Có tuyên bố chữa bệnh, điều trị, thay thế thuốc hoặc khỏi bệnh.
AUTHORITY_REFERENCE	Có sử dụng hoặc gọi nhắc uy tín bác sĩ, bệnh viện, cơ quan, chuyên gia hoặc truyền thông.
TESTIMONIAL	Có câu chuyện nhân chứng, phản hồi khách hàng hoặc trải nghiệm khỏi bệnh.
FEAR_URGENCY	Có yếu tố hù dọa, cảnh báo biến chứng, khan hiếm hoặc thúc ép hành động.
PRICE_PROMOTION	Có ưu đãi, giảm giá, khuyến mãi, cam kết hoàn tiền hoặc deal giới hạn.

3.4.2 Bộ nhãn hình ảnh

Bảng 3.4. Bộ nhãn hình ảnh dùng cho object detection

Nhãn	Vai trò	Ý nghĩa
Lab-coat	Lớp mục tiêu chính	Phát hiện áo blouse trắng, thường liên quan đến hình ảnh bác sĩ, chuyên gia y tế hoặc nhân vật được trình bày như chuyên gia.
logo	Lớp mục tiêu chính	Phát hiện logo hoặc biểu tượng xuất hiện trong ảnh quảng cáo, đặc biệt các logo có thể liên quan đến cơ quan, truyền thông hoặc tổ chức uy tín.
stethoscope	Lớp mục tiêu chính	Phát hiện ống nghe y tế, hỗ trợ nhận diện bối cảnh y khoa hoặc hình ảnh chuyên môn y tế.
Shirt	Lớp phụ/đối chứng	Phát hiện áo thông thường nhằm giúp mô hình phân biệt với áo blouse y tế. Lớp này không phải dấu hiệu rủi ro pháp lý độc lập.

3.5 Nguyên tắc gán nhãn

3.5.1 Dữ liệu văn bản

Mỗi mẫu văn bản được gán nhãn dựa trên nội dung thực tế và ngữ cảnh sử dụng, không chỉ dựa vào sự xuất hiện của từ khóa. Với nội dung dài, dữ liệu có thể được chia thành các đoạn phù hợp với đầu vào của mô hình, nhưng cần giữ liên kết với `post_id` gốc để kiểm soát leakage.

Các nhãn rủi ro được hiểu là tín hiệu hỗ trợ rà soát. Một mẫu có thể đồng thời có nhiều nhãn, ví dụ vừa là quảng cáo, vừa tuyên bố công dụng, vừa lợi dụng uy tín chuyên gia. Evidence nên được lưu lại khi có đoạn văn bản làm căn cứ rõ ràng.

3.5.2 Dữ liệu hình ảnh

Mỗi ảnh hoặc frame được gán nhãn theo đối tượng thị giác xuất hiện trong ảnh. Annotation cần xác định rõ bounding box của đối tượng, đặc biệt với các lớp dễ nhầm lẫn như Lab-coat

và Shirt. Việc thêm Shirt nhằm tạo lớp đối chứng để giảm nhầm lẫn trang phục, không nhầm mở rộng nhóm vi phạm chính.

Các nhãn Lab-coat, logo và stethoscope được xem là dấu hiệu hình ảnh có thể làm tăng rủi ro khi kết hợp với nội dung quảng cáo. Tuy nhiên, chỉ riêng sự xuất hiện của các đối tượng này chưa đủ để kết luận vi phạm; kết quả cần được hợp nhất với OCR, NLP, ASR, rule-based detection và ngữ cảnh bài đăng.

3.6 Chia tập dữ liệu

3.6.1 Dữ liệu văn bản

Dữ liệu văn bản được chia thành train, validation và test theo `post_id` để các đoạn thuộc cùng một bài đăng không xuất hiện đồng thời ở nhiều tập. Cách chia này giúp đánh giá khách quan hơn khả năng tổng quát hóa của mô hình trên bài đăng mới.

3.6.2 Dữ liệu hình ảnh

Dữ liệu hình ảnh cần được chia theo nguồn media gốc, video gốc hoặc `post_id` nếu có, nhằm tránh trường hợp các frame gần giống nhau xuất hiện ở cả train và test. Với dữ liệu Roboflow, cần lưu rõ version dataset, format export và các cảnh báo liên quan đến annotation để thuận tiện tái lập thực nghiệm.

CHƯƠNG 4:

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

4.1 Kiến trúc hệ thống

Hệ thống được thiết kế theo hướng pipeline đa module nhằm hỗ trợ phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng trên mạng xã hội. Sau giai đoạn thu thập và chuẩn hóa dữ liệu, các mô hình phát hiện được tổ chức thành những lớp xử lý độc lập, chạy song song để tạo điểm dự đoán riêng. Tầng hợp nhất ở cuối pipeline nhận kết quả từ từng lớp mô hình và tạo nhãn, xác suất, bằng chứng cùng điểm rủi ro tổng hợp. Cách thiết kế này giúp hệ thống dễ mở rộng khi cần bổ sung nguồn dữ liệu mới, mô hình mới hoặc nhóm tín hiệu rủi ro mới.

Về tổng thể, hệ thống gồm các lớp chức năng chính sau:

- **Lớp thu thập dữ liệu:** tiếp nhận bài đăng, video, metadata, đường dẫn nguồn và văn bản thô từ các nền tảng như TikTok hoặc Facebook.
- **Lớp xử lý và quản lý dữ liệu:** chuẩn hóa dữ liệu, loại bỏ trùng lặp, quản lý nhãn, chia tập train/validation/test và lưu phiên bản dataset.
- **Lớp rule-based detection:** đọc tập keyword, phát hiện cụm từ rủi ro, xác định nhãn gợi ý và lưu đoạn bằng chứng trong văn bản.
- **Lớp PhoBERT:** suy luận mô hình PhoBERT đã fine-tune cho phân loại đa nhãn và trả về `phobert_score` cho từng nhãn.
- **Lớp OCR:** trích xuất frame từ ảnh/video, nhận diện chữ nhúng và tạo `OCR_score` dựa trên nội dung chữ nhận diện được.
- **Lớp ASR:** trích xuất audio từ video, chuyển lời nói thành văn bản và tạo `ASR_score` từ nội dung transcript.

- **Lớp visual detection:** phát hiện các tín hiệu hình ảnh có rủi ro như áo blouse, ống nghe, phòng khám hoặc hình ảnh chuyên gia y tế và tạo `visual_score`.
- **Lớp hợp nhất và chấm điểm rủi ro:** kết hợp điểm từ các lớp chạy song song để tạo điểm rủi ro tổng hợp.
- **Lớp truy xuất và giải thích:** truy xuất quy định, nguyên tắc gán nhãn và bằng chứng liên quan để hỗ trợ sinh kết luận có giải thích.
- **Lớp API/Demo:** cung cấp chức năng dự đoán cho người dùng hoặc hệ thống bên ngoài, trả về nhãn, xác suất, bằng chứng và phân giải thích.


Luồng xử lý chính của hệ thống bắt đầu từ việc thu thập bài đăng hoặc video. Dữ liệu thô sau đó được chuẩn hóa và kiểm tra chất lượng trước khi đưa vào các lớp mô hình song song. Văn bản từ caption hoặc mô tả được đưa đồng thời vào rule-based detection và PhoBERT. Hình ảnh hoặc video được đưa đồng thời vào OCR, ASR và visual detection. Mỗi lớp trả về score, nhãn gợi ý và bằng chứng tương ứng; tầng fusion tiếp nhận các kết quả này để tạo nhãn dự đoán, xác suất cuối cùng và điểm rủi ro. Cuối cùng, hệ thống có thể sử dụng module RAG và LLM reasoning để sinh phần giải thích phục vụ rà soát thủ công.

Về mặt mô hình hóa, tầng hợp nhất có thể được biểu diễn bằng một hàm tổng hợp có trọng số trên các nguồn tín hiệu:

$$\text{risk_score}(x) = \sigma(b + w_p s_p(x) + w_{ocr} s_{ocr}(x) + w_{asr} s_{asr}(x) + w_v s_v(x) + w_r s_r(x))$$

Trong đó s_p , s_{ocr} , s_{asr} , s_v và s_r lần lượt là điểm từ PhoBERT, OCR, ASR, visual detection và rule-based detection; w là trọng số tương ứng; b là hệ số chệch; $\sigma(\cdot)$ là hàm sigmoid dùng để đưa điểm tổng hợp về khoảng $[0, 1]$. Công thức này thể hiện nguyên tắc late fusion: mỗi nhánh chỉ đóng góp một phần bằng chứng, kết quả cuối cùng không phụ thuộc tuyệt đối vào một mô hình đơn lẻ.

Overall architecture of the functional food advertising violation detection system



Hình 4.1. Kiến trúc tổng thể của hệ thống phát hiện dấu hiệu sai phạm trong quảng cáo thực phẩm chức năng

4.2 Thiết kế UC


Thiết kế UC mô tả các chức năng chính mà người dùng hoặc thành phần bên ngoài có thể tương tác với hệ thống. Trong phạm vi bản báo cáo đầu tiên, chương này tập trung vào các use case đã có đủ dữ liệu, quy trình và mã nguồn thực nghiệm để đặc tả chi tiết. Các tác nhân chính gồm người quản trị dữ liệu, người gán nhãn hoặc rà soát, người nghiên cứu và các nền tảng hỗ trợ như Google Drive, Roboflow, Ultralytics, Hugging Face Transformers. Danh sách use case chính gồm:

- **UC01 – Thu thập dữ liệu:** người quản trị dữ liệu thu thập bài đăng, video, metadata, đường dẫn nguồn và văn bản thô từ TikTok hoặc Facebook.

- **UC02 – Xử lý và chuẩn hóa dữ liệu:** người quản trị dữ liệu chuẩn hóa dữ liệu, kiểm tra duplicate bằng Python, tải media bằng yt-dlp và trích frame bằng FFmpeg.
- **UC03 – Quản lý và gán nhãn dữ liệu:** người gán nhãn sử dụng AI để hỗ trợ gán nhãn văn bản, trích evidence, review nhiều vòng và dùng Roboflow để gán nhãn hình ảnh.
- **UC04 – Chia tập và lưu phiên bản dataset:** người quản trị dữ liệu chia dữ liệu văn bản theo post_id để tránh leakage, còn dữ liệu hình ảnh được Roboflow chia tập và lưu phiên bản.
- **UC05 – Huấn luyện mô hình PhoBERT:** người nghiên cứu huấn luyện PhoBERT trên tập train, kiểm tra leakage theo post_id, chọn checkpoint tốt nhất, tune threshold và lưu mô hình.
- **UC06 – Huấn luyện mô hình YOLO v11:** người nghiên cứu tải dataset hình ảnh từ Roboflow, chuẩn hóa cấu hình YOLO, huấn luyện YOLO11m, đánh giá best.pt và lưu mô hình tốt nhất.

4.2.1 Đặc tả UC01 – Thu thập dữ liệu

UC01 mô tả chức năng thu thập dữ liệu thô từ TikTok/Facebook thông qua Apify và lưu trữ kết quả trên Google Drive. Đây là use case đầu vào của toàn bộ pipeline, vì chất lượng dữ liệu thu thập ảnh hưởng trực tiếp đến các bước xử lý, gán nhãn và huấn luyện mô hình phía sau.



Hình 4.2. Use case UC01 – Thu thập dữ liệu

Bảng 4.1. Đặc tả use case UC01 – Thu thập dữ liệu


Thành phần	Nội dung
Mã use case	UC01
Tên use case	Thu thập dữ liệu
Tác nhân chính	Người quản trị dữ liệu
Tác nhân phụ	Apify, TikTok/Facebook, Google Drive

Thành phần	Nội dung
Mục tiêu	Thu thập bài đăng, video, metadata, source URL, file/video link và văn bản thô từ TikTok/Facebook thông qua Apify, sau đó lưu dữ liệu thô lên Google Drive để phục vụ xử lý, gán nhãn và huấn luyện mô hình.
Tiền điều kiện	Người quản trị dữ liệu đã xác định nền tảng, từ khóa, nhóm sản phẩm hoặc danh sách URL cần thu thập; tác vụ Apify đã sẵn sàng để chạy.
Hậu điều kiện	Dữ liệu thô được lưu trên Google Drive, bao gồm raw text, metadata, source URL, file/video link, nền tảng và định danh mẫu dữ liệu.
Luồng chính	Bước 1: Người quản trị dữ liệu cấu hình tác vụ Apify. Bước 2: Người quản trị nhập từ khóa, nhóm sản phẩm hoặc URL bài đăng/video. Bước 3: Apify truy xuất bài đăng/video từ nền tảng nguồn. Bước 4: Hệ thống nhận kết quả crawl từ Apify. Bước 5: Hệ thống trích xuất hoặc chuẩn hóa text thô, metadata, source URL và file/video link. Bước 6: Hệ thống lưu dữ liệu thô lên Google Drive. Bước 7: Hệ thống trả về trạng thái thu thập thành công.

Thành phần	Nội dung
Luồng thay thế	Bước 1: Nếu URL không hợp lệ, bài đăng/video không truy cập được hoặc Apify trả lỗi, hệ thống ghi nhận lỗi và bỏ qua mẫu đó. Bước 2: Nếu dữ liệu đã tồn tại trên Google Drive, hệ thống đánh dấu trùng lặp để xử lý ở bước sau.
Dữ liệu đầu vào	Từ khóa, nhóm sản phẩm, URL bài đăng/video, nền tảng và cấu hình tác vụ Apify.
Dữ liệu đầu ra	Dữ liệu thô trên Google Drive gồm raw text, source URL, file/video link, platform, post/video id, thời gian thu thập và metadata liên quan.
Ngoại lệ	Apify lỗi, hết quota, URL lỗi, bài đăng/video bị xóa, nội dung bị giới hạn quyền truy cập, thiếu metadata hoặc không lưu được lên Google Drive.

4.2.2 Đặc tả UC02 – Xử lý và chuẩn hóa dữ liệu

UC02 mô tả chức năng xử lý dữ liệu thô sau khi thu thập. Hệ thống đọc dữ liệu từ Google Drive, chuẩn hóa văn bản và metadata, kiểm tra dữ liệu trùng lặp bằng Python, tải ảnh/video bằng yt-dlp, cắt video thành frame bằng FFmpeg và chỉ giữ các frame liên tiếp có độ khác biệt lớn hơn 70%. Kết quả của UC02 là bộ dữ liệu sạch hơn, có cấu trúc rõ hơn và sẵn sàng cho các bước gán nhãn, huấn luyện hoặc phân tích ảnh/video.



Hình 4.3. Use case UC02 – Xử lý và chuẩn hóa dữ liệu

Bảng 4.2. Đặc tả use case UC02 – Xử lý và chuẩn hóa dữ liệu

Thành phần	Nội dung
Mã use case	UC02

Thành phần	Nội dung
Tên use case	Xử lý và chuẩn hóa dữ liệu
Tác nhân chính	Người quản trị dữ liệu
Tác nhân phụ	Google Drive, Python, yt-dlp, FFmpeg
Mục tiêu	Chuẩn hóa dữ liệu thô sau thu thập, kiểm tra duplicate, tải media, cắt video thành frame và lưu lại dữ liệu đã xử lý để phục vụ gán nhãn, huấn luyện và phân tích đa phương thức.
Tiền điều kiện	Dữ liệu thô đã được lưu trên Google Drive; các trường như raw text, metadata, source URL và file/video link đã có ở mức tối thiểu; môi trường xử lý đã cài Python, yt-dlp và FFmpeg.
Hậu điều kiện	Dữ liệu đã được chuẩn hóa, mẫu trùng lặp được đánh dấu hoặc loại bỏ, media cần thiết được tải về, video được tách frame và các frame được lọc theo ngưỡng khác biệt lớn hơn 70%.


Thành phần	Nội dung
Luồng chính	Bước 1: Người quản trị dữ liệu cấu hình quy trình xử lý dữ liệu. Bước 2: Hệ thống đọc dữ liệu thô từ Google Drive. Bước 3: Hệ thống chuẩn hóa văn bản, metadata, source URL, định dạng thời gian và định danh mẫu. Bước 4: Hệ thống sử dụng Python để kiểm tra duplicate theo nội dung, URL, post/video id hoặc metadata liên quan. Bước 5: Hệ thống dùng yt-dlp để tải ảnh/video từ các link hợp lệ khi cần xử lý media. Bước 6: Hệ thống dùng FFmpeg để cắt video thành các frame liên tiếp. Bước 7: Hệ thống so sánh các frame liên tiếp và chỉ giữ frame có độ khác biệt lớn hơn 70% so với frame trước đó. Bước 8: Hệ thống lưu dữ liệu đã xử lý, log lỗi, danh sách duplicate và đường dẫn frame/media lên Google Drive.

Thành phần	Nội dung
Luồng thay thế	Bước 1: Nếu bản ghi bị thiếu text hoặc metadata quan trọng, hệ thống đánh dấu trạng thái cần kiểm tra thủ công. Bước 2: Nếu URL media không tải được bằng yt-dlp, hệ thống ghi log lỗi và vẫn giữ phần text/metadata đã chuẩn hóa. Bước 3: Nếu video lỗi hoặc FFmpeg không trích được frame, hệ thống bỏ qua nhánh frame và ghi lý do lỗi. Bước 4: Nếu các frame liên tiếp có độ khác biệt không vượt quá 70%, hệ thống loại frame sau để giảm trùng lặp hình ảnh.
Dữ liệu đầu vào	Dữ liệu thô trên Google Drive gồm raw text, metadata, source URL, file/video link, platform, post/video id và thời gian thu thập.
Dữ liệu đầu ra	Dữ liệu đã chuẩn hóa, danh sách duplicate, file media đã tải, frame đã lọc, log lỗi và metadata cập nhật.
Quy tắc xử lý	Duplicate được kiểm tra bằng Python; media được tải bằng yt-dlp; video được cắt bằng FFmpeg; chỉ giữ frame khi độ khác biệt với frame liền trước lớn hơn 70%.

Thành phần	Nội dung
Ngoại lệ	Thiếu trường dữ liệu bắt buộc, URL hỏng, media bị giới hạn quyền truy cập, yt-dlp/FFmpeg lỗi, không đủ dung lượng lưu trữ hoặc không ghi được kết quả lên Google Drive.

4.2.3 Đặc tả UC03 – Quản lý và gán nhãn dữ liệu

UC03 mô tả quy trình gán nhãn dữ liệu sau khi dữ liệu đã được chuẩn hóa ở UC02. Với dữ liệu văn bản, hệ thống sử dụng AI để chia các đoạn dài thành nhiều đoạn nhỏ đủ phù hợp với đầu vào của PhoBERT, gán `post_id` để tránh leakage khi chia train/validation/test, hỗ trợ gán nhãn và trích evidence dựa trên tập `keyword.json`. Kết quả gán nhãn văn bản được người rà soát kiểm tra lại và quy trình này được lặp ba lần để tăng độ tin cậy của dữ liệu. Với dữ liệu hình ảnh, Roboflow được sử dụng làm nền tảng chính để quản lý dataset, tạo model từ các dataset liên quan đến nhãn cần thiết, thêm các frame đã cắt ở UC02, auto label và review annotation.



Hình 4.4. Use case UC03 – Quản lý và gán nhãn dữ liệu

Bảng 4.3. Đặc tả use case UC03 – Quản lý và gán nhãn dữ liệu

Thành phần	Nội dung
Mã use case	UC03
Tên use case	Quản lý và gán nhãn dữ liệu
Tác nhân chính	Người gán nhãn và rà soát dữ liệu
Tác nhân phụ	AI hỗ trợ gán nhãn, keyword.json, PhoBERT, Roboflow, dataset hình ảnh liên quan, kho frame từ UC02

Thành phần	Nội dung
Mục tiêu	Tạo bộ dữ liệu văn bản và hình ảnh có nhãn đáng tin cậy, có evidence rõ ràng, hạn chế leakage khi chia tập và sẵn sàng cho huấn luyện mô hình PhoBERT hoặc mô hình thị giác.
Tiền điều kiện	Dữ liệu đã được xử lý ở UC02; văn bản, meta-data, post_id, frame và media liên quan đã có; file keyword.json và workspace Roboflow đã được chuẩn bị.
Hậu điều kiện	Dữ liệu văn bản có nhãn, đoạn evidence và trạng thái review; dữ liệu hình ảnh có annotation đã được kiểm tra; bộ dữ liệu đủ tin cậy sau ba vòng rà soát.


Thành phần	Nội dung
Luồng chính – văn bản	Bước 1: Hệ thống gán hoặc kiểm tra <code>post_id</code> cho từng mẫu để tránh leakage khi chia <code>train/validation/test</code>. Bước 2: AI hỗ trợ chia các đoạn văn bản dài thành nhiều đoạn nhỏ đủ phù hợp với giới hạn đầu vào của PhoBERT. Bước 3: AI sử dụng nội dung văn bản và file <code>keyword.json</code> để gợi ý một hoặc nhiều nhãn. Bước 4: AI trích evidence tương ứng với nhãn, ưu tiên các cụm từ hoặc đoạn văn bản thể hiện rõ dấu hiệu rủi ro. Bước 5: Người rà soát kiểm tra nhãn, evidence và trạng thái của từng mẫu. Bước 6: Quy trình gán nhãn và rà soát được lặp lại ba lần để tăng độ tin cậy của dữ liệu.

Thành phần	Nội dung
Luồng chính – hình ảnh	Bước 1: Người rà soát chuẩn bị các dataset hình ảnh liên quan đến các nhãn cần thiết trên Roboflow. Bước 2: Roboflow được dùng làm nền tảng chính để quản lý dataset và tạo model gán nhãn hình ảnh ban đầu. Bước 3: Hệ thống thêm các frame đã cắt ở UC02 vào workspace Roboflow. Bước 4: Roboflow thực hiện auto label cho các hình ảnh/frame mới. Bước 5: Người rà soát kiểm tra, sửa và xác nhận annotation sau auto label. Bước 6: Annotation đã review được lưu vào bộ dữ liệu hình ảnh phục vụ huấn luyện hoặc đánh giá.
Luồng thay thế	Bước 1: Nếu AI chia đoạn làm mất ngữ cảnh, người rà soát điều chỉnh lại đoạn văn bản hoặc gộp đoạn phù hợp. Bước 2: Nếu evidence không khớp với nhãn, người rà soát sửa evidence hoặc loại bỏ nhãn gợi ý. Bước 3: Nếu auto label trên Roboflow sai hoặc thiếu vùng annotation, người rà soát chỉnh sửa thủ công. Bước 4: Nếu một mẫu không đủ thông tin để gán nhãn, hệ thống đánh dấu trạng thái cần xem lại hoặc loại khỏi tập huấn luyện.

Thành phần	Nội dung
Dữ liệu đầu vào	Văn bản đã chuẩn hóa, metadata, post_id, frame từ UC02, file keyword.json, dataset hình ảnh liên quan và nhãn cần gán.
Dữ liệu đầu ra	Nhãn văn bản, evidence, đoạn văn bản đã chia nhỏ, trạng thái review, annotation hình ảnh, dataset đã rà soát và log chỉnh sửa.
Quy tắc xử lý	post_id được dùng để chống leakage; văn bản dài được chia nhỏ để phù hợp với PhoBERT; evidence phải gắn với nội dung cụ thể; quy trình gán nhãn văn bản được lặp ba lần; annotation hình ảnh phải được review sau auto label.
Ngoại lệ	Thiếu post_id, đoạn văn bản thiếu ngữ cảnh, file keyword.json chưa đầy đủ, nhãn AI gợi ý sai, Roboflow auto label sai, thiếu dataset hình ảnh liên quan hoặc annotation chưa đạt chất lượng.

4.2.4 Đặc tả UC04 – Chia tập và lưu phiên bản dataset

UC04 mô tả quy trình tạo các tập train, validation và test sau khi dữ liệu đã được gán nhãn và rà soát ở UC03. Điểm quan trọng của use case này là hai nhánh dữ liệu được quản lý theo hai cơ chế khác nhau. Với dữ liệu văn bản, người quản trị dữ liệu trực tiếp chia tập để bảo đảm toàn bộ mẫu hoặc đoạn văn bản có cùng post_id chỉ xuất hiện trong một tập duy nhất, nhờ đó hạn chế rò rỉ thông tin giữa huấn luyện và đánh giá. Với dữ liệu hình ảnh, việc chia tập được thực hiện trên Roboflow; nền tảng này lưu phiên bản dataset, thống kê phân phối lớp và cho phép xuất dữ liệu theo định dạng YOLO khi huấn luyện mô hình thị giác.



Hình 4.5. Use case UC04 – Chia tập và lưu phiên bản dataset

Bảng 4.4. Đặc tả use case UC04 – Chia tập và lưu phiên bản dataset

Thành phần	Nội dung
Mã use case	UC04
Tên use case	Chia tập và lưu phiên bản dataset
Tác nhân chính	Người quản trị dữ liệu
Tác nhân phụ	Google Drive, Roboflow, dữ liệu đã gán nhãn từ UC03
Mục tiêu	Tạo các tập train, validation và test cho dữ liệu văn bản và hình ảnh; bảo đảm dữ liệu văn bản không bị leakage theo post_id; lưu lại phiên bản dataset, thống kê phân phối nhãn và định dạng xuất phù hợp cho PhoBERT hoặc YOLO.
Tiền điều kiện	Dữ liệu văn bản và hình ảnh đã được gán nhãn, rà soát và lưu trạng thái ở UC03; mỗi mẫu văn bản có post_id hoặc mã nguồn tương đương; workspace Roboflow đã có bộ dữ liệu hình ảnh và annotation cần thiết.

Thành phần	Nội dung
Hậu điều kiện	Dữ liệu văn bản được chia tập thủ công và lưu trên Google Drive; dữ liệu hình ảnh được Roboflow chia tập, lưu phiên bản và có thể xuất theo định dạng YOLO; thống kê split và phân phối nhãn được ghi nhận để phục vụ huấn luyện và đánh giá.

Thành phần	Nội dung
Luồng chính – dữ liệu văn bản	Bước 1: Người quản trị dữ liệu mở bộ dữ liệu văn bản đã được gán nhãn và rà soát ở UC03. Bước 2: Người quản trị xác định các nhóm mẫu theo <code>post_id</code>; mỗi nhóm có thể gồm caption gốc, các đoạn đã chia nhỏ, evidence và nhãn tương ứng. Bước 3: Người quản trị chia dữ liệu thành các tập <code>train</code>, <code>validation</code> và <code>test</code> theo cách thủ công. Bước 4: Trong quá trình chia tập, toàn bộ mẫu có cùng <code>post_id</code> được đặt vào cùng một tập để tránh leakage giữa huấn luyện và đánh giá. Bước 5: Người quản trị kiểm tra lại phân phối nhãn ở từng tập, đặc biệt với các nhãn có ít mẫu hoặc nhãn rủi ro cao. Bước 6: Trường <code>split</code> được cập nhật cho từng dòng dữ liệu và file văn bản sau chia tập được lưu lên Google Drive. Bước 7: Thống kê số mẫu, số <code>post_id</code>, tỷ lệ nhãn và thời điểm tạo phiên bản được ghi lại trong <code>metadata dataset</code>.


Thành phần	Nội dung
Luồng chính – dữ liệu hình ảnh	Bước 1: Người quản trị kiểm tra bộ dữ liệu hình ảnh đã được annotation và review trên Roboflow. Bước 2: Người quản trị cấu hình tỷ lệ chia tập hoặc sử dụng cơ chế chia tập mặc định của Roboflow. Bước 3: Roboflow tự động phân chia ảnh và annotation thành các tập train, validation và test. Bước 4: Người quản trị kiểm tra thống kê phân phối lớp hình ảnh, gồm Lab-coat, logo, stethoscope và lớp phụ/đối chứng Shirt. Bước 5: Roboflow lưu lại phiên bản dataset, cấu hình tiền xử lý, thông tin augmentation nếu có và thống kê annotation. Bước 6: Khi huấn luyện YOLO, người quản trị xuất dataset từ Roboflow theo định dạng YOLO tương ứng với version đã chọn. Bước 7: Thông tin version Roboflow và thời điểm export được ghi lại để kết quả thực nghiệm có thể truy vết.

Thành phần	Nội dung
Luồng thay thế	Bước 1: Nếu phát hiện các mẫu có cùng <code>post_id</code> nằm ở nhiều tập khác nhau, người quản trị điều chỉnh lại trường <code>split</code> trước khi lưu dataset. Bước 2: Nếu phân phối nhãn văn bản quá lệch, người quản trị cân nhắc chia lại theo nhóm <code>post_id</code>, nhưng không phá vỡ ràng buộc cùng <code>post_id</code> trong một tập. Bước 3: Nếu một số mẫu văn bản thiếu <code>post_id</code>, người quản trị dùng URL, mã video hoặc mã bài đăng làm khóa thay thế; nếu vẫn không xác định được thì đánh dấu cần kiểm tra lại. Bước 4: Nếu Roboflow tạo split hình ảnh quá lệch hoặc thiếu lớp quan trọng trong tập đánh giá, người quản trị điều chỉnh cấu hình và tạo version dataset mới. Bước 5: Nếu export YOLO bị lỗi, người quản trị giữ nguyên version hiện tại, kiểm tra lại annotation hoặc cấu hình định dạng rồi thực hiện export lại.
Dữ liệu đầu vào	Dữ liệu văn bản đã gán nhãn, <code>post_id</code> , evidence, meta-data, dữ liệu hình ảnh đã annotation trên Roboflow và cấu hình chia tập mong muốn.

Thành phần	Nội dung
Dữ liệu đầu ra	File dữ liệu văn bản có trường <code>split</code> và metadata lưu trên Google Drive; version dataset hình ảnh trên Roboflow; file export định dạng YOLO; thống kê số mẫu, số ảnh, số annotation và phân phối nhãn theo từng tập.
Quy tắc xử lý	Dữ liệu văn bản do người quản trị chia thủ công; tất cả mẫu cùng <code>post_id</code> phải nằm trong cùng một tập; dữ liệu hình ảnh được Roboflow chia và lưu phiên bản; <code>Shirt</code> được ghi nhận là lớp phụ/đối chứng, không phải lớp vi phạm chính; mọi version dùng cho huấn luyện hoặc đánh giá phải có metadata để truy vết.
Ngoại lệ	Thiếu khóa nhóm văn bản, nhãn phân phối quá lệch, version Roboflow chưa đồng bộ, annotation hình ảnh chưa đạt chất lượng, lỗi export YOLO hoặc file trên Google Drive chưa cập nhật đúng phiên bản.

4.2.5 Đặc tả UC05 – Huấn luyện mô hình PhoBERT

UC05 mô tả quy trình huấn luyện mô hình PhoBERT cho bài toán phân loại đa nhãn trên dữ liệu văn bản. Quy trình này sử dụng file dữ liệu đã được chia tập từ UC04, trong đó người nghiên cứu kiểm tra đầy đủ các cột bắt buộc, kiểm tra leakage theo `post_id`, chuẩn hóa nhãn về dạng nhị phân, token hóa văn bản bằng tokenizer của PhoBERT, huấn luyện mô hình bằng loss có `pos_weight`, chọn checkpoint tốt nhất theo chỉ số `f1_balanced`, tune threshold trên validation set và lưu các artefact cần thiết để suy luận hoặc đánh giá lại.



Hình 4.6. Use case UC05 – Huấn luyện mô hình PhoBERT

Bảng 4.5. Đặc tả use case UC05 – Huấn luyện mô hình PhoBERT

Thành phần	Nội dung
Mã use case	UC05
Tên use case	Huấn luyện mô hình PhoBERT
Tác nhân chính	Người nghiên cứu
Tác nhân phụ	Google Drive, file dữ liệu văn bản từ UC04, tokenizer PhoBERT, thư viện Hugging Face Transformers, PyTorch, scikit-learn
Mục tiêu	Huấn luyện mô hình PhoBERT cho phân loại đa nhãn trên văn bản quảng cáo thực phẩm chức năng; kiểm soát leakage theo post_id; chọn checkpoint tốt nhất; tune threshold theo validation; lưu model, tokenizer, threshold, metadata và file dự đoán test để phục vụ đánh giá hoặc suy luận sau này.

Thành phần	Nội dung
Tiền điều kiện	File <code>dataset_real.csv</code> đã có các cột <code>text</code> , <code>split</code> và các cột nhãn; dữ liệu văn bản đã được chia thành <code>train</code> , <code>val</code> , <code>test</code> ở UC04; các mẫu cùng <code>post_id</code> phải nằm trong cùng một tập; môi trường huấn luyện có Python, PyTorch và Transformers.
Hậu điều kiện	Mô hình PhoBERT tốt nhất được lưu tại thư mục kết quả; <code>tokenizer</code> , <code>thresholds.json</code> , <code>labels.json</code> , <code>training_metadata.json</code> và file <code>test_predictions_with_probs.csv</code> được tạo để truy vết, đánh giá và kiểm tra thủ công.

Thành phần	Nội dung
Luồng chính – kiểm tra dữ liệu	Bước 1: Người nghiên cứu cấu hình đường dẫn dữ liệu, tên mô hình <code>vinai/phobert-base-v2</code>, thư mục lưu, <code>MAX_LENGTH</code>, <code>SEED</code>, danh sách nhãn và <code>threshold</code> ban đầu. Bước 2: Hệ thống đặt seed cho <code>random</code>, <code>numpy</code> và <code>torch</code>, đồng thời xác định thiết bị huấn luyện là CPU hoặc GPU. Bước 3: Hệ thống đọc <code>dataset_real.csv</code>, kiểm tra các cột bắt buộc gồm <code>text</code>, <code>split</code> và các cột nhãn. Bước 4: Hệ thống loại mẫu thiếu <code>text</code>, chuẩn hóa giá trị <code>split</code>, kiểm tra <code>split</code> chỉ thuộc <code>train</code>, <code>val</code>, <code>test</code>, đồng thời ép nhãn về giá trị 0 hoặc 1. Bước 5: Nếu có cột <code>post_id</code>, hệ thống kiểm tra từng <code>post_id</code> không xuất hiện ở nhiều <code>split</code> khác nhau để tránh leakage.

Thành phần	Nội dung
Luồng chính – tạo dữ liệu huấn luyện	Bước 1: Nếu có cột nguồn dữ liệu, hệ thống kiểm tra dữ liệu synthetic không nằm ngoài tập train. Bước 2: Hệ thống gộp các cột nhãn thành vector multi-label, tách dữ liệu thành <code>train_df</code>, <code>val_df</code> và <code>test_df</code>, đồng thời in thống kê phân phối nhãn theo từng split. Bước 3: Hệ thống tính <code>pos_weight</code> từ tập train, làm mềm bằng căn bậc hai và chặn trong khoảng hợp lý để tránh loss bị chi phối quá mạnh bởi nhãn hiếm. Bước 4: Hệ thống chuyển dữ liệu sang Hugging Face Dataset, token hóa bằng tokenizer PhoBERT với <code>MAX_LENGTH = 256</code> và kiểm tra tỷ lệ mẫu bị truncate.


Thành phần	Nội dung
Luồng chính – huấn luyện và đánh giá	Bước 1: Hệ thống khởi tạo <code>AutoModelForSequenceClassification</code> với <code>problem_type = multi_label_classification</code> và số nhãn bằng độ dài danh sách nhãn. Bước 2: Hệ thống huấn luyện bằng <code>WeightedTrainer</code>, sử dụng <code>BCEWithLogitsLoss</code> có <code>pos_weight</code>, batch size 16, learning rate $2e^{-5}$, tối đa 12 epoch và early stopping. Bước 3: Trong quá trình huấn luyện, hệ thống chọn checkpoint tốt nhất theo <code>f1_balanced</code>, được tính từ trung bình của <code>f1_macro</code> và <code>f1_micro</code>. Bước 4: Sau huấn luyện, hệ thống dự đoán trên validation set, tune threshold riêng cho từng nhãn, sau đó chặn threshold trong khoảng đã cấu hình để hạn chế overfit validation nhỏ. Bước 5: Hệ thống đánh giá lại validation và test bằng threshold cuối cùng, tính <code>exact_match_accuracy</code>, <code>f1_macro</code>, <code>f1_micro</code>, <code>precision_macro</code>, <code>recall_macro</code> và metric theo từng nhãn. Bước 6: Hệ thống lưu model, tokenizer, threshold, danh sách nhãn, metadata huấn luyện và file dự đoán test có xác suất để phục vụ kiểm tra thủ công.

Thành phần	Nội dung
Luồng thay thế – kiểm tra dữ liệu	Bước 1: Nếu thiếu cột bắt buộc, hệ thống dừng huấn luyện và báo danh sách cột thiếu. Bước 2: Nếu tồn tại split khác train, val, test, hệ thống dừng để người nghiên cứu chỉnh lại file dữ liệu. Bước 3: Nếu phát hiện post_id xuất hiện ở nhiều split, hệ thống dừng và yêu cầu chia lại dữ liệu ở UC04. Bước 4: Nếu một split rỗng, hệ thống dừng vì không thể huấn luyện hoặc đánh giá đúng quy trình.
Luồng thay thế – cấu hình huấn luyện	Bước 1: Nếu tỷ lệ mẫu dài hơn MAX_LENGTH vượt 20%, hệ thống cảnh báo để người nghiên cứu cân nhắc tăng độ dài đầu vào nếu tài nguyên GPU cho phép. Bước 2: Nếu nhãn hiếm làm pos_weight quá lớn, hệ thống dùng cơ chế căn bậc hai và chặn trên để giảm rủi ro mô hình dự đoán quá nhiều positive. Bước 3: Nếu validation nhỏ khiến threshold tự động dao động mạnh, threshold cuối cùng được chặn bằng THRESHOLD_BOUNDS.
Dữ liệu đầu vào	File dataset_real.csv, cột text, cột split, post_id nếu có, các nhãn EFFICACY_CLAIM, CURE_CLAIM, AUTHORITY_REFERENCE, TESTIMONIAL, FEAR_URGENCY, PRICE_PROMOTION, IS_ADS.

Thành phần	Nội dung
Dữ liệu đầu ra	Mô hình PhoBERT đã huấn luyện, tokenizer, thresholds.json, labels.json, training_metadata.json, kết quả validation/test, classification report và test_predictions_with_probs.csv.
Quy tắc xử lý	Bài toán được xử lý theo hướng multi-label; mỗi nhãn có threshold riêng; checkpoint được chọn bằng f1_balanced; dữ liệu có cùng post_id không được xuất hiện ở nhiều split; dữ liệu synthetic nếu có chỉ được nằm trong train; kết quả test cần lưu xác suất để người nghiên cứu rà soát lỗi.
Ngoại lệ	Thiếu file dữ liệu, thiếu cột bắt buộc, split sai, leakage theo post_id, một split rỗng, lỗi tải tokenizer/model, thiếu tài nguyên GPU, lỗi ghi artefact hoặc file dự đoán.

4.2.6 Đặc tả UC06 – Huấn luyện mô hình YOLO v11

UC06 mô tả quy trình huấn luyện mô hình YOLO v11 cho nhánh thị giác của hệ thống. Quy trình này sử dụng bộ dữ liệu hình ảnh đã được quản lý trên Roboflow ở UC04, cụ thể là project doctor-and-medical, version 7, export theo định dạng YOLO. Người nghiên cứu tải dataset về môi trường huấn luyện, chuẩn hóa file data.yaml, kiểm tra số lượng ảnh, file nhãn và phân phối lớp, sau đó fine-tune mô hình yolo11m.pt bằng thư viện Ultralytics. Sau huấn luyện, hệ thống dùng best.pt để đánh giá trên tập test nếu tồn tại, hoặc val nếu không có tập test, sinh biểu đồ đánh giá, chạy dự đoán thử trên ảnh đánh giá và sao chép mô hình tốt nhất sang file artefact cuối cùng.



Hình 4.7. Use case UC06 – Huấn luyện mô hình YOLO v11

Bảng 4.6. Đặc tả use case UC06 – Huấn luyện mô hình YOLO v11

Thành phần	Nội dung
Mã use case	UC06
Tên use case	Huấn luyện mô hình YOLO v11
Tác nhân chính	Người nghiên cứu
Tác nhân phụ	Google Colab hoặc môi trường GPU, Google Drive, Roboflow, Ultralytics YOLO, file <code>data.yaml</code> , bộ dữ liệu hình ảnh từ UC04
Mục tiêu	Huấn luyện mô hình YOLO v11 để phát hiện các đối tượng hình ảnh liên quan đến bối cảnh quảng cáo thực phẩm chức năng; kiểm tra cấu trúc dataset Roboflow; đánh giá mô hình tốt nhất bằng các chỉ số object detection; lưu <code>best.pt</code> và các biểu đồ phục vụ phân tích kết quả.

Thành phần	Nội dung
Tiền điều kiện	Dataset hình ảnh đã được gán nhãn và version hóa trên Roboflow; workspace Roboflow có quyền truy cập API; môi trường huấn luyện đã có GPU hoặc tài nguyên đủ chạy YOLO; Google Drive đã sẵn sàng để lưu kết quả; các lớp hình ảnh được định nghĩa nhất quán, gồm Lab-coat, logo, stethoscope và lớp phụ/đối chứng Shirt.
Hậu điều kiện	Thư mục kết quả YOLO được lưu trên Google Drive; best.pt, last.pt, biểu đồ huấn luyện, confusion matrix, PR/F1/P/R curve, kết quả validation và ảnh dự đoán mẫu được tạo; mô hình tốt nhất được sao chép thành best_doctor_medical_yolo11m_v7.pt.

Thành phần	Nội dung
Luồng chính – chuẩn bị môi trường và dataset	Bước 1: Người nghiên cứu cài hoặc kiểm tra các thư viện cần thiết gồm ultralytics, roboflow, supervision và pyyaml. Bước 2: Hệ thống kiểm tra môi trường Ultralytics để xác nhận phiên bản thư viện, thiết bị và cấu hình thực thi. Bước 3: Người nghiên cứu mount Google Drive và tạo thư mục lưu kết quả <code>/content/drive/MyDrive/tpcn_yolo_runs</code>. Bước 4: Người nghiên cứu nhập Roboflow API key để truy cập workspace <code>hs-workspace-8odgk</code>. Bước 5: Hệ thống tải project <code>doctor-and-medical</code>, version 7, theo định dạng <code>yolov11</code> về thư mục <code>/content/datasets/doctor-and-medical-v7</code>. Bước 6: Hệ thống đọc file <code>data.yaml</code>, chuẩn hóa trường <code>path</code>, <code>train</code>, <code>val</code> và <code>test</code> để Ultralytics có thể huấn luyện đúng vị trí ảnh và nhãn. Bước 7: Hệ thống kiểm tra số lượng ảnh, số file nhãn ở từng split và in danh sách lớp từ <code>data.yaml</code>. Bước 8: Hệ thống đếm phân phối object theo lớp trong tập <code>train</code> để người nghiên cứu phát hiện sớm mất cân bằng dữ liệu hoặc lớp hiếm.

Thành phần	Nội dung
Luồng chính – huấn luyện mô hình	Bước 1: Người nghiên cứu chọn mô hình khởi tạo MODEL_NAME = yolo11m.pt và tên phiên chạy doctor_medical_yolo11m_v7_640_fast. Bước 2: Hệ thống thiết lập cấu hình huấn luyện gồm EPOCHS = 100, IMGSZ = 640, BATCH = 16 và PATIENCE = 25. Bước 3: Hệ thống khởi tạo đối tượng YOLO(MODEL_NAME) từ thư viện Ultralytics. Bước 4: Hệ thống gọi model.train với task = detect, optimizer AdamW, learning rate ban đầu lr0 = 0.001, cos_lr = True, close_mosaic = 10, augment = True, seed = 42, deterministic = True, device = 0, workers = 2 và amp = True. Bước 5: Trong quá trình huấn luyện, Ultralytics lưu checkpoint, log, metric và biểu đồ vào thư mục SAVE_DIR/RUN_NAME; nếu validation không cải thiện sau số epoch kiên nhẫn, cơ chế early stopping dừng huấn luyện.

Thành phần	Nội dung
Luồng chính – đánh giá, dự đoán và xuất mô hình	Bước 1: Hệ thống mở các biểu đồ kết quả nếu tồn tại, gồm <code>results.png</code>, <code>confusion_matrix.png</code>, <code>PR_curve.png</code>, <code>F1_curve.png</code>, <code>P_curve.png</code> và <code>R_curve.png</code>. Bước 2: Hệ thống lấy checkpoint tốt nhất tại <code>RUN_DIR/weights/best.pt</code> và khởi tạo lại mô hình YOLO từ checkpoint này. Bước 3: Hệ thống chọn split đánh giá là <code>test</code> nếu thư mục <code>test/images</code> tồn tại, ngược lại dùng <code>val</code>. Bước 4: Hệ thống chạy <code>trained_model.val</code> với <code>imgsz = 640</code>, sinh plot đánh giá và in các chỉ số <code>mAP50-95</code>, <code>mAP50</code> và <code>mAP75</code>. Bước 5: Hệ thống chạy <code>trained_model.predict</code> trên ảnh của split đánh giá với <code>conf = 0.25</code>, <code>iou = 0.5</code> và lưu ảnh có bounding box dự đoán. Bước 6: Người nghiên cứu xem một số ảnh dự đoán đầu tiên để kiểm tra trực quan chất lượng phát hiện. Bước 7: Hệ thống sao chép <code>best.pt</code> thành <code>best_doctor_medical_yolo11m_v7.pt</code> trong thư mục lưu kết quả cuối cùng.

Thành phần	Nội dung
Luồng thay thế – dữ liệu và cấu hình	Bước 1: Nếu Roboflow API key không hợp lệ hoặc không có quyền truy cập project, hệ thống dừng ở bước tải dataset và yêu cầu người nghiên cứu kiểm tra lại quyền truy cập. Bước 2: Nếu <code>data.yaml</code> thiếu đường dẫn <code>valid/images</code>, hệ thống kiểm tra biến thể <code>val/images</code>; nếu cả hai không tồn tại, người nghiên cứu phải kiểm tra lại export dataset. Bước 3: Nếu số ảnh và số file nhãn ở một split chênh lệch bất thường, người nghiên cứu kiểm tra lại quá trình export hoặc annotation trên Roboflow trước khi train. Bước 4: Nếu phân phối lớp quá lệch hoặc lớp quan trọng gần như không có mẫu trong validation/test, người nghiên cứu tạo lại version Roboflow hoặc điều chỉnh dữ liệu trước khi đánh giá chính thức. Bước 5: Nếu môi trường không có GPU, thiếu bộ nhớ hoặc batch size 16 gây lỗi, người nghiên cứu giảm batch size, tắt AMP hoặc chuyển sang máy có tài nguyên phù hợp. Bước 6: Nếu không có tập test, hệ thống dùng tập validation để đánh giá tạm thời và ghi rõ split đã dùng trong tên thư mục kết quả.

Thành phần	Nội dung
Dữ liệu đầu vào	Roboflow API key, project doctor-and-medical, version 7, file data.yaml, ảnh và label định dạng YOLO, mô hình khởi tạo yolo11m.pt, cấu hình huấn luyện và thư mục Google Drive để lưu kết quả.
Dữ liệu đầu ra	Thư mục chạy doctor_medical_yolo11m_v7_640_fast, checkpoint best.pt và last.pt, file best_doctor_medical_yolo11m_v7.pt, biểu đồ huấn luyện, kết quả validation, ảnh dự đoán mẫu và các metric object detection.
Quy tắc xử lý	YOLO chỉ phát hiện đối tượng hình ảnh và trả về bounding box, class, confidence; kết quả của nhánh này là bằng chứng thị giác, không phải kết luận vi phạm pháp lý. Dataset hình ảnh được chia và version hóa trên Roboflow; lớp Shirt được dùng như lớp phụ/đối chứng; mọi lần huấn luyện phải ghi lại version dataset, cấu hình mô hình, seed và thư mục kết quả để truy vết.
Ngoại lệ	Lỗi cài thư viện, lỗi mount Drive, API key Roboflow sai, project/version không tồn tại, thiếu file data.yaml, thiếu ảnh hoặc label, lỗi cấu hình split, lỗi GPU, huấn luyện dừng sớm, thiếu checkpoint best.pt, lỗi lưu hoặc sao chép mô hình cuối.

Trong phạm vi bản báo cáo đầu tiên, sáu use case trên tập trung vào chuỗi công việc đã có căn cứ triển khai: thu thập dữ liệu, xử lý dữ liệu, gán nhãn, chia tập, huấn luyện PhoBERT và huấn luyện YOLO v11. Các chức năng suy luận, OCR, ASR, rule-based detection, fusion,

API demo và xuất kết quả rà soát vẫn thuộc kiến trúc tổng thể của đề tài, nhưng sẽ được đặc tả thành use case riêng ở các phiên bản báo cáo tiếp theo khi quy trình triển khai đã đủ ổn định.

CHƯƠNG 5:

PHƯƠNG PHÁP ĐỀ XUẤT

5.1 Tổng quan phương pháp

Phương pháp đề xuất được xây dựng theo hướng đa phương thức, trong đó mỗi nhánh mô hình khai thác một dạng tín hiệu khác nhau của quảng cáo thực phẩm chức năng trên mạng xã hội. Nhánh PhoBERT xử lý văn bản; nhánh YOLO xử lý hình ảnh; OCR và ASR chuyển chữ trong ảnh/video và lời nói thành văn bản; rule-based detection phát hiện các mẫu biểu đạt rủi ro rõ ràng. Các nhánh này không thay thế nhau mà cùng đóng góp vào tổng hợp nhất rủi ro.

Đầu ra của từng nhánh gồm score, nhãn gợi ý và bằng chứng tương ứng. Tầng fusion tổng hợp các score này để tạo `risk_score`. Cách thiết kế này phù hợp với bài toán vì dấu hiệu rủi ro có thể nằm ở nhiều kênh khác nhau: caption, chữ trên poster, lời thoại, đối tượng hình ảnh hoặc cách dùng logo/biểu tượng uy tín.

5.2 Nhánh phân tích văn bản bằng PhoBERT

5.2.1 Biểu diễn bài toán

Bài toán văn bản được mô hình hóa dưới dạng phân loại đa nhãn. Với mỗi văn bản đầu vào, mô hình dự đoán xác suất cho từng nhãn như `IS_ADS`, `EFFICACY_CLAIM`, `CURE_CLAIM`, `AUTHORITY_REFERENCE`, `TESTIMONIAL`, `FEAR_URGENCY` và `PRICE_PROMOTION`. Một mẫu có thể được gán nhiều nhãn cùng lúc vì nội dung quảng cáo thường chứa nhiều dạng tín hiệu rủi ro.

5.2.2 Tiền xử lý văn bản

Các bước tiền xử lý gồm chuẩn hóa Unicode, loại bỏ ký tự nhiễu không cần thiết, xử lý khoảng trắng, kiểm tra trường dữ liệu bắt buộc và tách dữ liệu theo `post_id`. Với dữ liệu mạng xã hội, một số ký hiệu đặc trưng như emoji, dấu chấm xen giữa chữ hoặc cách viết biến dạng cần được xem xét thận trọng vì có thể là tín hiệu lách kiểm duyệt.

5.2.3 Huấn luyện và tối ưu

Đề tài sử dụng PhoBERT-base-v2 làm encoder tiếng Việt và bổ sung classification head gồm 7 đầu ra sigmoid. Mô hình được triển khai bằng lớp phân loại chuỗi của Transformers, với `problem_type` đặt ở chế độ phân loại đa nhãn.

Với mỗi nhãn i , mô hình sinh ra logit z_i . Xác suất dự đoán được tính bằng hàm sigmoid:

$$p_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}$$

Sau đó, xác suất được so sánh với threshold riêng của từng nhãn:

$$\hat{y}_i = \begin{cases} 1, & p_i \geq \tau_i \\ 0, & p_i < \tau_i \end{cases}$$

Trong đó τ_i là ngưỡng quyết định của nhãn i . Cách thiết lập threshold riêng theo nhãn phù hợp với dữ liệu mất cân bằng, vì các nhãn hiếm và nhãn phổ biến thường cần ngưỡng khác nhau.

Do dữ liệu có hiện tượng mất cân bằng, đặc biệt ở các nhãn hiếm, quá trình huấn luyện sử dụng `BCEWithLogitsLoss` kết hợp `pos_weight`. Trọng số dương được tính dựa trên tỷ lệ âm/dương trong tập huấn luyện, sau đó làm mềm và giới hạn trong khoảng hợp lý để giảm nguy cơ tăng false positive quá mức.

Hàm mất mát nhị phân có trọng số cho bài toán đa nhãn được biểu diễn như sau:

$$\mathcal{L}_{BCE} = -\frac{1}{C} \sum_{i=1}^C [w_i y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

Trong đó C là số nhãn, y_i là nhãn thật, p_i là xác suất dự đoán và w_i là trọng số dương của nhãn i . Đoạn code huấn luyện PhoBERT là hợp lý vì có kiểm tra cột bắt buộc, kiểm tra leakage theo `post_id`, làm mềm `pos_weight`, chọn checkpoint theo F1 cân bằng và tune threshold cuối cùng trên validation set. Điểm cần lưu ý là threshold được tune trên validation nhỏ có thể overfit, vì vậy việc chặn biên threshold trong code là phù hợp.

Checkpoint được chọn theo chỉ số cân bằng giữa macro F1 và micro F1:

$$F1_{balanced} = 0.5 \times F1_{macro} + 0.5 \times F1_{micro}$$

Sau khi chọn checkpoint, threshold của từng nhãn được tune trên validation set và chặn trong khoảng hợp lý. Cách làm này giúp quyết định nhãn cuối cùng phù hợp hơn so với dùng ngưỡng cố định 0.5 cho mọi nhãn.

Bảng 5.1. Tóm tắt pipeline nhánh PhoBERT

Giai đoạn	Thành phần	Mục tiêu
Dữ liệu	CSV, split theo <code>post_id</code>	Hạn chế leakage và chuẩn hóa đầu vào.
Tiền xử lý	Tokenizer PhoBERT, max length	Chuyển văn bản thành input cho mô hình.
Huấn luyện	PhoBERT, weighted BCE	Học các nhãn rủi ro trong văn bản.
Tối ưu	Checkpoint theo F1 cân bằng, tune threshold	Cân bằng hiệu quả tổng thể và hiệu quả trên nhãn hiếm.
Đầu ra	<code>phobert_score</code> , nhãn dự đoán, evidence	Cung cấp tín hiệu văn bản cho tầng fusion.

5.3 Nhánh phát hiện hình ảnh bằng YOLO

5.3.1 Mục tiêu của nhánh hình ảnh

Nhánh YOLO được dùng để phát hiện các đối tượng hình ảnh có liên quan đến bối cảnh y tế hoặc dấu hiệu mạo danh/lợi dụng uy tín trong ảnh, poster hoặc frame video quảng cáo. Mô hình chỉ phát hiện sự xuất hiện của đối tượng và tạo bằng chứng hình ảnh; việc xác định mức độ rủi ro cuối cùng cần kết hợp với NLP, OCR, ASR, rule-based detection và logic hợp nhất.

5.3.2 Nhãn và vai trò

Ba lớp mục tiêu chính gồm Lab-coat, logo và stethoscope. Lab-coat giúp nhận diện hình ảnh áo blouse trắng, thường gắn với bác sĩ hoặc chuyên gia y tế. logo hỗ trợ phát hiện nguy cơ mạo danh hoặc lợi dụng uy tín của tổ chức, cơ quan hoặc truyền thông. stethoscope giúp nhận diện bối cảnh y khoa thông qua ống nghe.

Lớp Shirt được bổ sung như lớp phụ/đối chứng nhằm giúp mô hình phân biệt áo thông thường với áo blouse y tế. Lớp này không được xem là lớp vi phạm chính và không nên diễn giải như một dấu hiệu rủi ro pháp lý độc lập.

5.3.3 Công nghệ và cấu hình huấn luyện

Dataset hình ảnh được quản lý và gán nhãn trên Roboflow với tên doctor-and-medical, version 7, export theo YOLO format. Mô hình được huấn luyện trên Google Colab với GPU Tesla T4 bằng framework Ultralytics YOLO. Model sử dụng là YOLO11m pretrained weights cho task object detection, input image size 640 x 640 và file cấu hình dataset data.yaml. Checkpoint best.pt được chọn để đánh giá.

Bảng 5.2. Cấu hình huấn luyện chính của nhánh YOLO

Thành phần	Giá trị
Model	YOLO11m pretrained weights
Task	Object Detection
Input size	640 x 640
Epochs	100
Batch size	16
Optimizer	AdamW
Learning rate khởi tạo	$1e-04 = 0.0001$
Cosine learning rate	True
Patience	25
Augmentation	True
close_mosaic	10
Mixed precision AMP	True

Cấu hình huấn luyện YOLO trong code là hợp lý với bối cảnh Google Colab và GPU Tesla T4: mô hình YOLO11m có năng lực tốt hơn các biến thể nhỏ, `imgsz=640` là kích thước phổ biến cho object detection, `batch=16` có thể chấp nhận được khi bật AMP, AdamW và cosine learning rate giúp quá trình tối ưu ổn định hơn, còn `close_mosaic=10` giúp giảm ảnh hưởng augmentation mosaic ở các epoch cuối. Cấu hình `seed=42`, `deterministic=True`, `workers=2` và `amp=True` cũng phù hợp để tăng khả năng tái lập và kiểm soát tài nguyên. Nếu Colab hết bộ nhớ GPU, batch size có thể giảm xuống 8 nhưng không làm thay đổi logic phương pháp.

5.3.4 Đầu ra của nhánh YOLO

Đầu ra của YOLO gồm bounding box, nhãn đối tượng và confidence. Các kết quả này được chuyển thành `visual_score` hoặc bằng chứng hình ảnh cho tầng fusion. Ví dụ, một frame có Lab-coat và logo sẽ được ghi nhận là có tín hiệu thị giác cần xem xét, nhưng mức rủi

ro chỉ được đánh giá đầy đủ khi kết hợp với nội dung văn bản hoặc OCR/ASR liên quan.

Confidence score của một dự đoán object detection có thể được hiểu là mức tin cậy tổng hợp giữa khả năng có đối tượng trong bounding box và xác suất lớp tương ứng:

$$\text{Conf}(B, c) = P(\text{object} \mid B) \times P(c \mid B, \text{object})$$

Trong đó B là bounding box dự đoán, c là lớp đối tượng, $P(\text{object} \mid B)$ là xác suất vùng B thật sự chứa đối tượng và $P(c \mid B, \text{object})$ là xác suất đối tượng thuộc lớp c . Trong báo cáo này, confidence được dùng để xếp hạng và lọc các dự đoán hình ảnh, không được diễn giải như xác suất vi phạm pháp lý.

Độ khớp giữa bounding box dự đoán B_p và bounding box thật B_{gt} được đo bằng Intersection over Union (IoU):

$$\text{IoU}(B_p, B_{gt}) = \frac{|B_p \cap B_{gt}|}{|B_p \cup B_{gt}|}$$

IoU càng cao thì vùng dự đoán càng trùng khớp với vùng gán nhãn. Trong đánh giá object detection, một dự đoán thường được xem là đúng nếu nhãn lớp đúng và IoU vượt qua ngưỡng đánh giá.

Ở mức tổng quát, loss của YOLO có thể được mô tả như tổ hợp của các thành phần định vị hộp, phân loại lớp và phân phối vị trí:

$$\mathcal{L}_{YOLO} = \lambda_{box} \mathcal{L}_{box} + \lambda_{cls} \mathcal{L}_{cls} + \lambda_{dfl} \mathcal{L}_{dfl}$$

Trong đó $\mathcal{L}_{box}$ phản ánh sai lệch vị trí bounding box, $\mathcal{L}_{cls}$ phản ánh sai lệch phân loại lớp, $\mathcal{L}_{dfl}$ là thành phần distribution focal loss trong các phiên bản YOLO hiện đại, còn λ là trọng số cân bằng giữa các thành phần. Công thức này được dùng để giải thích nguyên lý huấn luyện ở mức khái quát, không thay thế chi tiết cài đặt nội bộ của Ultralytics.

5.4 OCR, ASR và rule-based detection

OCR được sử dụng để trích xuất chữ trong poster, ảnh sản phẩm hoặc frame video. Nội dung OCR sau đó được đưa vào nhánh phân tích văn bản và rule-based detection. ASR được sử dụng để chuyển lời nói trong video thành transcript, giúp hệ thống phát hiện các tuyên bố rủi ro không xuất hiện trong caption.

Rule-based detection đóng vai trò phát hiện các mẫu ngôn ngữ rõ ràng như cụm từ cam kết khỏi bệnh, khẳng định công dụng tuyệt đối, hoặc cách viết biến dạng có thể được mô tả bằng luật. Nhánh này có ưu điểm dễ giải thích nhưng không đủ linh hoạt nếu dùng độc lập, vì vậy chỉ nên xem là một nguồn tín hiệu hỗ trợ.

5.5 Hợp nhất điểm rủi ro

Tầng fusion nhận các đầu ra từ PhoBERT, YOLO, OCR, ASR và rule-based detection. Mục tiêu của tầng này là tổng hợp bằng chứng từ nhiều nhánh để tạo `risk_score` và nhãn gợi ý cuối cùng.

Trong phiên bản ban đầu, fusion có thể được triển khai theo hướng late fusion với trọng số hoặc luật tổng hợp đơn giản. Các phiên bản sau có thể học trọng số fusion từ dữ liệu đã được review thủ công. Dù sử dụng cơ chế nào, kết quả cuối cùng vẫn cần lưu lại bằng chứng theo từng nhánh để người rà soát hiểu vì sao mẫu được đánh dấu rủi ro.

5.6 Nguyên tắc diễn giải kết quả

Kết quả của từng nhánh cần được diễn giải theo đúng phạm vi. PhoBERT cho biết khả năng văn bản chứa một nhóm dấu hiệu rủi ro; YOLO cho biết ảnh hoặc frame có đối tượng hình ảnh liên quan; OCR và ASR bổ sung nội dung chữ hoặc lời nói; rule-based detection cung cấp evidence theo mẫu luật. Không nhánh nào tự chứng minh vi phạm pháp lý nếu đứng riêng lẻ. Kết luận phục vụ rà soát cần dựa trên tổng hợp nhiều tín hiệu và ngữ cảnh cụ thể của quảng cáo.

CHƯƠNG 6:

THỰC NGHIỆM VÀ ĐÁNH GIÁ

6.1 Thiết lập thực nghiệm đa phương thức

Thực nghiệm được tổ chức theo hai nhánh chính: nhánh phân tích văn bản bằng PhoBERT và nhánh phát hiện hình ảnh bằng YOLO. Hai nhánh này đánh giá các dạng tín hiệu khác nhau và cùng đóng góp vào hệ thống tổng. Kết quả của từng nhánh không được diễn giải như kết luận pháp lý độc lập, mà là bằng chứng hỗ trợ tăng hợp nhất rủi ro.

Nhánh PhoBERT sử dụng PhoBERT-base-v2 được fine-tune cho bài toán phân loại đa nhãn bằng lớp phân loại chuỗi của Transformers. Nhánh YOLO sử dụng YOLO11m pre-trained weights, huấn luyện trên dataset Roboflow doctor-and-medical version 7, export theo YOLO format và đánh giá bằng checkpoint best.pt.

6.2 Dữ liệu và chỉ số đánh giá

6.2.1 Dữ liệu văn bản

Bảng 6.1. Thống kê số lượng mẫu văn bản theo tập dữ liệu

Tập dữ liệu	Số mẫu	Tỷ lệ
Train	2289	82.1%
Validation	249	8.9%
Test	249	8.9%

Tổng số mẫu văn bản sau khi chia tập là 2787. Quá trình chia dữ liệu theo post_id không phát hiện nhóm leakage giữa các tập, với Post_id leakage groups bằng 0.

Bảng 6.2. Thống kê phân phối nhãn văn bản

Nhãn	Số mẫu dương	Tỷ lệ	Nhận xét
IS_ADS	1327	47.6%	Nhãn quảng cáo tổng quát có số mẫu dương lớn nhất.
EFFICACY_CLAIM	1233	44.2%	Nhãn công dụng xuất hiện phổ biến trong dữ liệu.
CURE_CLAIM	397	14.2%	Nhãn chữa bệnh có số mẫu trung bình.
AUTHORITY_REFERENCE	658	23.6%	Nhãn tham chiếu uy tín xuất hiện tương đối nhiều.
TESTIMONIAL	117	4.2%	Nhãn hiếm, cần theo dõi khi đánh giá macro F1.
FEAR_URGENCY	124	4.4%	Nhãn hiếm, dễ bị ảnh hưởng bởi mất cân bằng dữ liệu.
PRICE_PROMOTION	365	13.1%	Nhãn khuyến mãi có số mẫu trung bình.

6.2.2 Dữ liệu hình ảnh

Test set của nhánh YOLO gồm 160 ảnh, 256 object instances và 1 ảnh nền. Mô hình đánh giá là YOLO11m với 20,033,887 tham số và 67.7 GFLOPs. Các lớp được đánh giá gồm Lab-coat, logo, stethoscope và Shirt.

6.2.3 Chỉ số đánh giá

Với nhánh PhoBERT, các chỉ số gồm exact match accuracy, precision, recall, macro F1 và micro F1. Macro F1 phản ánh hiệu quả trên từng nhãn theo trung bình không trọng số, còn micro F1 phản ánh hiệu quả tổng thể trên toàn bộ dự đoán.

Các chỉ số Precision, Recall và F1 được tính từ số lượng true positive (TP), false

positive (FP) và false negative (FN):

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Với bài toán đa nhãn, exact match accuracy yêu cầu toàn bộ vector nhãn dự đoán phải trùng với vector nhãn thật:

$$\text{ExactMatch} = \frac{1}{N} \sum_{j=1}^N \mathbf{1}(\hat{\mathbf{y}}^{(j)} = \mathbf{y}^{(j)})$$

Trong đó N là số mẫu, $\hat{\mathbf{y}}^{(j)}$ là vector nhãn dự đoán và $\mathbf{y}^{(j)}$ là vector nhãn thật của mẫu thứ j .

Với nhánh YOLO, Precision cho biết tỷ lệ dự đoán đúng trong các object được mô hình phát hiện, Recall cho biết tỷ lệ object thật được phát hiện, mAP50 là mean average precision tại ngưỡng IoU 0.5, mAP50-95 là mAP trung bình trên nhiều ngưỡng IoU từ 0.5 đến 0.95, còn mAP75 là mAP tại ngưỡng IoU 0.75. mAP50-95 khắt khe hơn vì đánh giá cả chất lượng định vị bounding box ở nhiều mức IoU.

Average Precision (AP) của một lớp được hiểu là diện tích dưới đường cong Precision–Recall:

$$AP_c = \int_0^1 P_c(r) dr$$

mAP tại một ngưỡng IoU t là trung bình AP trên C lớp:

$$\text{mAP}@t = \frac{1}{C} \sum_{c=1}^C AP_c(t)$$

Với mAP50-95, kết quả được lấy trung bình trên các ngưỡng IoU từ 0.50 đến 0.95 với bước 0.05:

$$\text{mAP}_{50:95} = \frac{1}{10} \sum_{t \in \{0.50, 0.55, \dots, 0.95\}} \text{mAP}@t$$

6.3 Kết quả nhánh văn bản PhoBERT

6.3.1 Threshold và kết quả tổng quan

Bảng 6.3. Threshold cuối cùng dùng để đánh giá validation/test

Nhãn	Threshold
EFFICACY_CLAIM	0.57
CURE_CLAIM	0.73
AUTHORITY_REFERENCE	0.59
TESTIMONIAL	0.65
FEAR_URGENCY	0.27
PRICE_PROMOTION	0.60
IS_ADS	0.65

Bảng 6.4. Kết quả tổng quan của PhoBERT trên validation và test

Tập	Exact match	Macro F1	Micro F1	Macro P	Macro R
Validation	0.6747	0.7522	0.8468	0.7191	0.8304
Test	0.6546	0.6413	0.8183	0.6115	0.6790

6.3.2 Kết quả theo nhãn

Bảng 6.5. Kết quả PhoBERT theo từng nhãn trên tập test

Nhãn	P	R	F1	Support	Nhận xét
EFFICACY_CLAIM	0.7177	0.8812	0.7911	101	Recall cao, phù hợp với mục tiêu phát hiện claim công dụng.
CURE_CLAIM	0.8056	0.8286	0.8169	35	Kết quả tương đối ổn định dù support thấp hơn nhãn công dụng.
AUTHORITY_REFERENCE	0.7808	0.9344	0.8507	61	Nhãn đạt F1 cao trong các nhóm nội dung rủi ro.
TESTIMONIAL	0.0000	0.0000	0.0000	4	Chưa học tốt do số mẫu dương rất ít.
FEAR_URGENCY	0.2857	0.4000	0.3333	5	Kết quả còn hạn chế do nhãn hiếm và biểu đạt đa dạng.
PRICE_PROMOTION	0.8333	0.7812	0.8065	32	Tín hiệu khuyến mãi tương đối rõ, F1 đạt mức tốt.
IS_ADS	0.8571	0.9273	0.8908	110	Nhãn quảng cáo tổng quát đạt kết quả tốt.

Trên tập test, PhoBERT đạt micro F1 là 0.8183 và macro F1 là 0.6413. Chênh lệch giữa micro F1 và macro F1 cho thấy mô hình hoạt động tốt hơn trên các nhãn phổ biến, trong khi hiệu quả giảm ở các nhãn hiếm như TESTIMONIAL và FEAR_URGENCY. Kết quả này phù hợp với đặc điểm dữ liệu mất cân bằng và cho thấy cần tiếp tục mở rộng các nhóm nhãn hiếm.

6.4 Kết quả nhánh hình ảnh YOLO

6.4.1 Kết quả tổng thể

Bảng 6.6. Kết quả tổng thể của YOLO11m trên test set

Chỉ số	Giá trị
Test images	160
Object instances	256
Background images	1
Parameters	20,033,887
GFLOPs	67.7
Precision	0.898
Recall	0.818
mAP50	0.872
mAP75	0.830
mAP50-95	0.733
Preprocess speed	5.7 ms/image
Inference speed	27.6 ms/image
Postprocess speed	1.5 ms/image

Kết quả tổng thể cho thấy mô hình YOLO11m bước đầu phát hiện tương đối tốt các đối tượng hình ảnh liên quan đến bối cảnh y tế hoặc mạo danh uy tín trong quảng cáo. mAP50 đạt 0.872 và mAP50-95 đạt 0.733, cho thấy mô hình có khả năng phát hiện object ở mức khá, đồng thời vẫn còn dư địa cải thiện về định vị bounding box ở các ngưỡng IoU khắt khe hơn.

6.4.2 Kết quả theo từng lớp

Bảng 6.7. Kết quả YOLO11m theo từng lớp trên test set


Lớp	Images	Inst.	P	R	mAP50	Nhận xét
Lab-coat	47	52	0.858	0.808	0.870	Nhận diện khá tốt áo blouse trắng, là lớp mục tiêu chính.
Shirt	54	96	0.815	0.635	0.730	Lớp phụ/đối chứng, recall thấp hơn nhưng không phải lớp vi phạm chính.
logo	80	97	0.927	0.921	0.948	Lớp có kết quả tốt nhất, quan trọng cho nhóm nguy cơ mạo danh/lợi dụng uy tín.
stethoscope	10	11	0.992	0.909	0.939	Kết quả cao nhưng số mẫu còn ít, cần thận trọng khi kết luận độ ổn định.

Bảng 6.8. mAP50-95 theo từng lớp của YOLO11m

Lớp	mAP50-95
Lab-coat	0.749
Shirt	0.602
logo	0.835
stethoscope	0.747

Nếu chỉ xét ba lớp mục tiêu chính Lab-coat, logo và stethoscope, kết quả trung bình xấp xỉ đạt Precision 0.926, Recall 0.879, mAP50 0.919 và mAP50-95 0.777. Điều này cho thấy các lớp phục vụ trực tiếp cho phát hiện dấu hiệu hình ảnh rủi ro có kết quả tốt hơn trung bình chung khi không tính lớp phụ Shirt.

6.4.3 Trực quan hóa kết quả YOLO




(a) Ma trận nhầm lẫn theo số lượng

(b) Ma trận nhầm lẫn chuẩn hóa

Hình 6.1. Ma trận nhầm lẫn của YOLO11m trên tập test


Hai ma trận nhầm lẫn trong Hình 6.1 hỗ trợ phân tích các trường hợp mô hình nhận diện sai hoặc bỏ sót object theo từng lớp. Ma trận chuẩn hóa giúp quan sát tỷ lệ lỗi giữa các lớp có số lượng mẫu khác nhau, trong khi ma trận theo số lượng cho thấy quy mô thực tế của từng nhóm lỗi.



(a) Đường cong Precision–Recall

(b) Đường cong F1 theo confidence

Hình 6.2. Đường cong PR và F1 của YOLO11m trên tập test



(a) Precision theo confidence

(b) Recall theo confidence

Hình 6.3. Đường cong Precision và Recall của YOLO11m trên tập test

Các đường cong trong Hình 6.2 và Hình 6.3 cho thấy sự đánh đổi giữa Precision và Recall khi thay đổi ngưỡng confidence. Trong hệ thống đề xuất, các hình này được dùng để hiểu hành vi kỹ thuật của nhánh YOLO và lựa chọn ngưỡng suy luận phù hợp; chúng không phải bằng chứng độc lập để kết luận một nội dung quảng cáo vi phạm pháp lý.

6.4.4 Phân tích kết quả YOLO

logo là lớp có kết quả tốt nhất với $mAP_{50} = 0.948$ và $mAP_{50-95} = 0.835$. Đây là tín hiệu quan trọng vì logo hoặc biểu tượng tổ chức có thể liên quan đến nhóm nguy cơ mạo danh hoặc lợi dụng uy tín. Lab-coat đạt $mAP_{50} = 0.870$ và $mAP_{50-95} = 0.749$, cho thấy mô hình nhận diện khá tốt hình ảnh áo blouse trắng.

stethoscope đạt Precision và Recall cao, nhưng chỉ có 11 instances trên test set. Vì vậy, kết quả của lớp này nên được xem là tín hiệu bước đầu, cần bổ sung thêm mẫu để đánh giá chắc chắn hơn. Shirt có Recall thấp hơn, nhưng đây là lớp phụ được thêm vào để giảm nhầm lẫn với Lab-coat; do đó không nên diễn giải Shirt như dấu hiệu rủi ro pháp lý độc lập.

6.5 Thảo luận chung

Kết quả thực nghiệm cho thấy hai nhánh PhoBERT và YOLO bổ sung cho nhau. PhoBERT phát hiện các tín hiệu ngôn ngữ như tuyên bố công dụng, tuyên bố chữa bệnh hoặc tham chiếu uy tín. YOLO phát hiện các dấu hiệu hình ảnh như áo blouse, logo và ống nghe. Khi được kết hợp trong tầng fusion, các tín hiệu này có thể giúp ưu tiên các mẫu quảng cáo cần rà soát kỹ hơn.

Tuy nhiên, cả hai nhánh đều có giới hạn riêng. PhoBERT gặp khó khăn với các nhãn hiếm và các cách diễn đạt gián tiếp. YOLO chỉ phát hiện đối tượng hình ảnh và không hiểu đầy đủ ngữ cảnh pháp lý. Vì vậy, kết quả cuối cùng cần được tổng hợp với OCR, ASR, rule-based detection và kiểm tra thủ công.

6.6 Hạn chế và hướng cải thiện

Các hạn chế chính gồm:

- Test set hình ảnh hiện mới gồm 160 ảnh, cần mở rộng thêm để đánh giá chắc chắn hơn.
- Lớp stethoscope có số lượng mẫu ít nên kết quả có thể chưa đại diện đầy đủ.
- Dataset có cảnh báo lẫn giữa bounding box và segmentation annotation; trong quá trình đánh giá, Ultralytics chỉ sử dụng bounding box. Cần chuẩn hóa lại dataset ở version sau để tránh warning.
- Một số nhãn văn bản như TESTIMONIAL và FEAR_URGENCY có support thấp, làm giảm macro F1.
- Cơ chế fusion hiện cần được hoàn thiện thêm để học hoặc hiệu chỉnh trọng số giữa các nhánh.

Trong các phiên bản tiếp theo, đề tài cần mở rộng dữ liệu thật, tăng số mẫu cho các lớp/nhãn hiếm, chuẩn hóa annotation hình ảnh, bổ sung đánh giá OCR/ASR và kiểm thử

tầng fusion trên tập dữ liệu đa phương thức đã được review thủ công.

CHƯƠNG 7:

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã xây dựng hướng tiếp cận phát hiện dấu hiệu rủi ro trong quảng cáo thực phẩm chức năng trên mạng xã hội theo kiến trúc đa phương thức. Thay vì chỉ dựa vào một mô hình đơn lẻ, hệ thống kết hợp các nhánh PhoBERT, YOLO, OCR, ASR, rule-based detection và tăng hợp nhất rủi ro. Cách tiếp cận này phù hợp với đặc điểm quảng cáo mạng xã hội, nơi tín hiệu rủi ro có thể xuất hiện đồng thời trong văn bản, hình ảnh, video và lời nói.

Kết quả thực nghiệm cho thấy PhoBERT có khả năng phát hiện tương đối tốt một số nhóm tín hiệu văn bản phổ biến như quảng cáo tổng quát, tuyên bố công dụng, tuyên bố chữa bệnh, tham chiếu uy tín và khuyến mãi. Nhánh YOLO bước đầu phát hiện được các đối tượng hình ảnh liên quan đến bối cảnh y tế hoặc mạo danh uy tín như Lab-coat, logo và stethoscope. Các kết quả này là cơ sở để xây dựng `risk_score` tổng hợp, nhưng chưa thay thế vai trò đánh giá pháp lý hoặc rà soát chuyên môn.

7.2 Ưu điểm

- Kiến trúc hệ thống được thiết kế theo hướng module, giúp các nhánh PhoBERT, YOLO, OCR, ASR và rule-based detection có thể phát triển độc lập nhưng vẫn đóng góp vào tầng fusion chung.
- Bộ nhãn văn bản phản ánh nhiều nhóm dấu hiệu rủi ro thường gặp trong quảng cáo thực phẩm chức năng, phù hợp với bài toán phân loại đa nhãn.
- Bộ nhãn hình ảnh đã tách rõ các lớp mục tiêu chính và lớp phụ/đối chứng Shirt, giúp hạn chế diễn giải sai vai trò của nhãn.
- Kết quả được trình bày theo hướng hỗ trợ rà soát, có metric, bằng chứng và phân tích

hạn chế thay vì khẳng định kết luận tuyệt đối.

7.3 Hạn chế

- Dữ liệu mạng xã hội có nhiều cách diễn đạt gián tiếp, teencode hoặc lách luật, gây khó khăn cho mô hình văn bản.
- Một số nhãn văn bản còn mất cân bằng, đặc biệt TESTIMONIAL và FEAR_URGENCY, làm giảm macro F1.
- Test set hình ảnh hiện còn nhỏ; lớp stethoscope có số lượng instance ít nên cần thận trọng khi đánh giá độ ổn định.
- Dataset hình ảnh cần được chuẩn hóa thêm để tránh lẫn giữa bounding box và segmentation annotation.
- Cơ chế fusion hiện mới ở mức thiết kế và cần thêm dữ liệu đa phương thức đã review để đánh giá định lượng đầy đủ.

7.4 Hướng phát triển

- Mở rộng bộ dữ liệu văn bản và hình ảnh từ nhiều nền tảng, nhóm sản phẩm và phong cách quảng cáo khác nhau.
- Bổ sung dữ liệu cho các nhãn hiếm trong văn bản và các lớp hình ảnh có ít mẫu, đặc biệt stethoscope.
- Chuẩn hóa lại dataset Roboflow ở các version sau, bảo đảm annotation nhất quán theo bounding box cho bài toán object detection.
- Đánh giá riêng các module OCR và ASR, sau đó đưa kết quả vào pipeline văn bản và rule-based detection.
- Hoàn thiện tầng fusion/risk scoring, có thể bắt đầu bằng late fusion có trọng số và tiến tới học trọng số từ dữ liệu đã được review thủ công.

- Xây dựng giao diện hỗ trợ người rà soát xem nhãn dự đoán, điểm rủi ro, bounding box, evidence văn bản và nguồn tín hiệu đóng góp vào kết quả.

7.5 Kết luận chung

Nhìn chung, đề tài đã đặt nền tảng cho một hệ thống hỗ trợ phát hiện dấu hiệu rủi ro quảng cáo thực phẩm chức năng theo hướng đa phương thức. PhoBERT và YOLO không được xem là các mô hình thay thế nhau, mà là hai nguồn tín hiệu bổ sung trong cùng pipeline. Khi được kết hợp với OCR, ASR, rule-based detection và quy trình review thủ công, hệ thống có thể hỗ trợ ưu tiên các nội dung cần kiểm tra sâu hơn trong các phiên bản tiếp theo.

TÀI LIỆU THAM KHẢO

- [1] Quốc hội, *Luật Quảng cáo 2012*, Việt Nam, 2012.
- [2] Chính phủ, *Nghị định 15/2018/NĐ-CP quy định chi tiết thi hành một số điều của Luật An toàn thực phẩm*, Việt Nam, 2018.
- [3] Chính phủ, *Nghị định 38/2021/NĐ-CP quy định xử phạt vi phạm hành chính trong lĩnh vực văn hóa và quảng cáo*, Việt Nam, 2021.